
分类号:

单位代码:10560

密 级:

汕 頭 大 學
碩 士 學 位 論 文



中文题名: 多模态对话场景下的情绪原因对识别
研究

英文题名: Research on Multimodal Emotion-Cause Pair
Extraction in Conversations

姓 名 _____ 学 号 _____

所在学院 数学与计算机学院 导 师 _____

专 业 人工智能 合作导师 无

入学日期 _____ 年 月 日 答辩日期 _____ 年 月 日

论文提交日期 _____ 年 月 日

学位论文原创性声明

本论文是我个人在导师指导下进行的工作研究及取得的研究成果。论文中除了特别加以标注和致谢的地方外，不包含其他人或其它机构已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在论文中以明确方式标明。本人完全意识到本声明的法律责任由本人承担。

作者签名：

年 月 日

学位论文使用授权声明

本人授权汕头大学保存本学位论文的电子和纸质文档，允许论文被查阅和借阅；学校可将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或其它复制手段保存和汇编论文；学校可以向国家有关部门或机构送交论文并授权其保存、借阅或上网公布本学位论文的全部或部分内容。对于保密的论文，按照保密的有关规定和程序处理。

本论文属于：保密（），在年解密后适用本授权声明。

不保密（√）。（请在以上括号内打“√”）

作者签名：

导师签名：

年 月 日

摘要

多模态对话场景下的情绪原因对抽取 (Multimodal Emotion-Cause Pair Extraction, MECPE) 旨在从同时包含文本、语音与视觉信息的多模态对话场景中识别出蕴含情绪的对话语句并进一步定位触发该情绪的原因话语。由于真实对话中的模态信息并不同步呈现, 且情绪原因对之间的因果关系常常隐含在跨轮次语境之中, 现有 MECPE 研究虽然已有一定积累, 但在复杂场景下仍面临若干关键困难, 概括起来主要体现在以下两个方面: 1) 传统模型大多建立在相关性学习基础上, 即只根据情感句和原因句之间的特征表示进行相关性学习, 因而容易受到“虚假相关性”的干扰。例如, 模型可能过度依赖某一模态中的局部噪声, 导致“模态偏差”; 也可能因为话语在对话中位置相近, 就把它们机械地判断为因果配对, 导致“位置偏差”。在缺乏真正的因果效应分析的情况下, 这类方法往往在在处理跨模态歧义和长程依赖时出现稳定性交叉的情况。2) 近年来, 大语言模型开始广泛应用于各项研究中, 其中就包括 MECPE 任务, 但大模型内部决策过程仍然具有较强黑箱性, 缺乏显式的因果校验环节, 容易把预训练语料中的统计偏好误当作有效依据, 生成看似逻辑通顺, 但是并不符合对应对话场景的因果推理。同时, MECPE 任务要求模型兼顾多模态融合、长时序建模以及隐含情绪推理, 现有方法往往依赖闭源大模型或较大参数规模的大语言模型。相比之下, 边缘侧可部署的小参数多模态模型在参数量小以及精度下降的情况下, 处理复杂多模态因果推理任务时性能更易明显下降。因此, 如何在有限算力条件下提升小参数大语言模型在 MECPE 任务中的推理能力, 仍是值得持续研究的问题。

围绕上述问题, 本文从因果建模、偏差抑制和小参数大语言模型能力激发三个方面展开研究, 设计了两类方法: 1) 针对虚假相关性和位置偏差问题, 本文提出反事实多模态去偏框架 Counterfactual Multimodal Debiasing (CMD)。该框架将 MECPE 从单纯的相关性拟合任务改写为基于结构因果模型的干预过程: 在特征层面, 通过对特定模态实施可控掩码来构造反事实输入, 据此估计并削弱模态特定噪声的影响; 在输出层面, 结合双分支位置感知策略, 对依赖物理距离的捷径学习施加约束, 使模型更多依靠跨模态语义及上下文逻辑完成预测。2) 针对生成式模型中的黑箱幻觉、模态缺失以及小参数模型推理能力受限等问题, 本文提出基于双视角推理与混合适配器的 MoAD (Mixture-of-Adapters via

Dual-perspective) 框架。该框架以单一多模态大模型为底座, 在不同推理阶段加载功能不同的适配器, 分别从“由情绪回溯原因”(E-C) 和“由原因推演情绪”(C-E) 两个方向完成 MECPE 推理, 并在结果层面实施交叉校验。与此同时, 本文还构造了错误驱动的模式缺失思维链训练数据, 用于弥补小模型在复杂语境和信息残缺条件下的推理短板。

实验结果表明, 上述方法在公开 MECPE 数据集上取得了较有竞争力的结果, 并说明从因果约束、偏差抑制和双视角推理等环节协同优化, 能够有效提升该任务的处理效果; 其中, 小参数模型也展现出较好的应用潜力。

关键词: 多模态; 情绪原因对抽取; 反事实去偏; 混合适配器; 双视角推理; 大语言模型

Abstract

Multimodal Emotion-Cause Pair Extraction (MECPE) aims to identify emotional utterances and locate their causes in multimodal conversations containing text, audio, and visual data. In real conversations, modalities are rarely synchronized, and causal relations often hide across multiple dialogue turns. Despite existing progress, MECPE faces two key challenges in complex scenarios. Firstly, traditional models rely on simple correlation learning between emotion and cause features. This makes them vulnerable to "spurious correlations." For instance, over-relying on local noise in one modality causes "modality bias." Mechanically pairing adjacent utterances causes "position bias." Without true causal analysis, these methods struggle with cross-modal ambiguity and long-range dependencies. Secondly, Large Language Models are increasingly applied to MECPE. However, their internal decision-making remains a black box without explicit causal verification. They often mistake statistical priors from pre-training for valid evidence, producing inferences that seem logical but do not fit the specific context. Furthermore, MECPE requires multimodal fusion, long-sequence modeling, and implicit reasoning. Current methods rely heavily on closed-source or massive LLMs. In contrast, lightweight, edge-deployable multimodal models suffer severe performance drops in complex causal reasoning tasks. Enhancing the reasoning capability of small LLMs under limited computing resources is a critical problem.

To address these issues, this thesis explores causal modeling, bias suppression, and capability elicitation for small LLMs. We propose two main frameworks: Firstly, to tackle spurious correlations and position bias, we propose the Counterfactual Multimodal Debiasing (CMD) framework. CMD shifts MECPE from simple correlation fitting to an intervention process based on Structural Causal Models. At the feature level, it uses controllable masking on specific modalities to construct counterfactual inputs. This estimates and mitigates modality-specific noise. At the output level, a dual-branch position-aware strategy constrains shortcut learning based on physical distance. This forces the model to rely on actual cross-modal semantics

and context logic. Secondly, to address black-box hallucinations, modality missing, and limited reasoning in small models, we propose the Mixture-of-Adapters via Dual-perspective (MoAD) framework. Built on a single multimodal LLM, MoAD loads specific adapters at different reasoning stages. It performs MECPE inference from two directions: Emotion-to-Cause (E-C) and Cause-to-Emotion (C-E), followed by cross-verification. Additionally, we construct an error-driven chain-of-thought dataset with missing modalities. This helps overcome the reasoning limitations of small models in complex contexts with incomplete information.

Experimental results on public MECPE datasets demonstrate competitive performance. The findings indicate that jointly optimizing causal constraints, bias suppression, and dual-perspective reasoning effectively improves task performance. Notably, small-parameter models exhibit strong application potential.

Keywords: Multimodal; Emotion-Cause Pair Extraction; Counterfactual Debiasing; Mixture-of-Adapters; Dual-Perspective Reasoning; Large Language Models

目录

摘要	I
Abstract	III
目录	V
第一章 绪论	1
1.1 研究背景和意义	1
1.2 国内外研究现状	3
1.2.1 多模态对话情感与原因抽取研究	3
1.2.2 结构因果模型与多模态去偏研究	4
1.3 论文的主要研究内容	5
1.4 论文组织结构	6
第二章 论文的理论概要	7
2.1 引言	7
2.2 预训练模型	7
2.2.1 Transformer	7
2.2.2 RoBERTa	8
2.2.3 HuBERT	9
2.2.4 Vision Transformer (ViT)	10
2.3 大语言模型	11
2.4 参数高效微调 (PEFT)	12
2.5 结构化因果模型 (SCM) 与反事实推理	错误! 未定义书签。
2.5.1 结构化因果模型 (SCM)	14
2.5.2 因果阶梯与认知层级	14
2.5.3 因果干预与后门准则	15
第三章 基于反事实多模态去偏的情绪原因对抽取模型	16
3.1 引言	16
3.2 任务定义	16
3.3 因果去偏的理论基石与结构因果模型	17
3.4 方法	18
3.4.1 多模态基础特征提取	19
3.4.2 多模态去偏模块	20
3.4.3 情绪引导的因果抽取	22
3.4.4 鲁棒双仿射配对与位置去偏	23
3.4.4.1 注入概率先验的双仿射语义分支	24
3.4.4.2 基于 Rubi-Focal Loss 的梯度截断去偏	25
3.5 实验	26
3.5.1 实验设置	26
3.5.2 对比模型	27
3.5.3 主要成果	28
3.5.4 消融实验与干预机制验证	30
3.5.5 案例研究与决策边界剖析 (Case Study)	32
3.6 本章小结	34
第四章 基于双视角认知与混合适配器的推理框架	35

4.1 引言	35
4.2 任务重构	35
4.3 方法	36
4.3.1 动态滑动窗口与多粒度关键帧采样	错误! 未定义书签。
4.3.3 双视角适配器推理机制	错误! 未定义书签。
4.3.3.1 E-C 流: 基于模态必要性的反事实溯源	41
4.3.3.2 C-E 流: 基于多任务辅助增强的隐式线索推理	错误! 未定义书签。
4.3.4 自适应集合逻辑融合	错误! 未定义书签。
4.4 实验	46
4.4.1 数据集及评估指标	46
4.4.2 实验设置	47
4.4.3 实验结果	47
4.4.4 消融实验	48
4.5 本章小节	53
第五章 总结与展望	54
5.1 本文总结	54
5.2 展望	55
参考文献	56

第一章 绪论

1.1 研究背景和意义

近些年,随着深度学习、深度学习与生成式人工智能技术持续演进,人工智能系统的任务重心已不再局限于简单的分类任务和回归预测任务,而是逐步转向对复杂环境、用户状态及交互语境的综合感知^[1]。在人机交互、医疗诊断、在线教育与心理健康监测等情绪敏感度较高的应用场景中,系统如果只能机械式的响应指令,往往难以满足实际需求;它还需要理解对话中的情绪在什么时候出现、为什么会产生,以及这种情绪变化将如何影响后续交互。

情绪信息既是说话人外部行为表现与其内部心理状态之间的重要连接点,也是情感计算领域长期关注的核心对象。自 Picard 于 1995 年提出情感计算理论框架以来^[2],计算机“识别并理解人类情绪”的研究路径逐渐清晰^[3]。相关工作也由早期主要依赖文本线索的单模态分析,逐步扩展到融合音频信息、视觉信息和上下文信息的多模态建模,并进一步把研究重点从“识别情绪类别”推进到“解释情绪为何产生”这一更深层的问题^{[4][5]}。

并且随着流媒体平台和社交网络的普及,使得真实对话中的情绪表达研究得到了规模更大、形态更复杂的数据基础。人在自然交流中表达情绪时,通常不只依赖某一句话的字面信息,而是借助面部表情、身体动作、语调节奏以及文本内容共同传递态度和立场^[6]。也正因为如此,对话情绪识别(ERC)逐步成为自然语言处理和情感计算的重要研究问题^[7]。不过,传统 ERC 研究更多停留在情绪标签分类层面,对于“情绪由何而来”的讨论仍显不足。为弥补这一缺口,研究视角进一步延伸到情绪原因对抽取(ECPE)及其多模态扩展任务之中,要求模型不仅判断情绪类别,还要在上下文中定位触发情绪的关键话语或事件^{[8][9]}。

然而,仅靠多模态特征的对齐与融合,只会让模型学到对话之间的相关性表示,还不足以完整解释情绪从外部刺激到内部心理反应的形成过程。认知心理学中的情绪评价理论(Cognitive Appraisal Theory)指出,情绪并非个体对外部事件的机械性反应,而是个体结合自身目标、经验和所处情境,对外部刺激进行主观评价之后形成的结果^[10]。换言之,情绪生成本身包含一条由“外界刺激进入”

到“内部评价加工”再到“情绪反应形成”的隐性链条。如果模型只能学习多模态融合后的特征呈现出的相关性关系，而无法在一定程度上重建这一认知路径，那么它对情绪原因的判断就难以保持稳定。

进一步来看，真实对话往往伴随多名参与者、频繁的话轮切换以及大量非结构化的异构信息。多模态情绪原因对抽取（Multimodal Emotion-Cause Pair Extraction, MECPE）正是在这一背景下受到广泛关注的。该任务要求模型在跨轮次、跨模态的联合约束下，同时识别情绪话语与对应的触发源，既要完成文本、语音和视觉之间的对齐，也要理解多轮互动中因果关系如何逐步形成和传递^[11,12]。因此，MECPE 并不是单纯的标签预测问题，而是一项兼具语义理解、时序建模和因果推断性质的复杂任务。

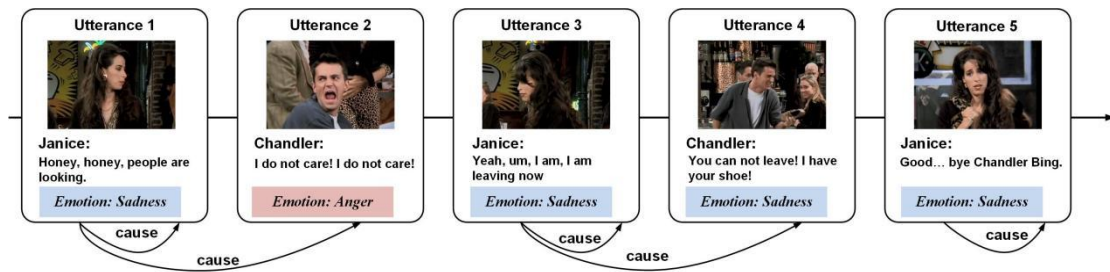


图 1-1 多模态对话情绪原因对识别实例

图 1-1 给出了一个典型的 MECPE 场景示例。该片段取自多模态对话数据集，包含 Janice 与 Chandler 之间连续五轮对话。图中直观展示了文本内容和对应的视频帧，而在实际数据中，每一轮话语还同时配有音频信息，例如语调、音高、音强和停顿等声学线索。MECPE 的目标并不是仅判断某一句话携带何种情绪，而是要求模型在完整对话流中，把目标情绪话语与其真正的触发话语准确对应起来。以图中片段为例，Janice 在第三轮表现出的“悲伤”并不是由单一文本信号触发的，而是与 Chandler 在上一轮中的语言内容“I do not care!”、面部表情变化以及更强烈的语气表达共同相关；随后，Janice 的离开又可能成为下一轮情绪变化的诱因，使 Chandler 在后续话轮中出现新的情绪反应。这个例子说明，情绪及其原因往往跨越多轮对话，模型若想得到可靠判断，就必须同时整合多模态线索，并结合上下文来分析因果链条如何在对话推进中逐步传递。

尽管 MECPE 兼具明确的研究价值与应用价值，但现有模型在处理这类深层因果推理问题时仍存在较为突出的性能瓶颈，集中表现为以下两个方面：

- (1) 很多数据驱动方法主要依赖表征层面的相关性判断，缺少显式的因果

干预机制。这样一来，模型很容易受到数据分布中模态偏差的影响，把计算资源过多投入到文本内容，视觉噪声或者局部高频特征上；同时，在长对话中又容易直接把情绪句位置相邻的话语当作原因节点。结果往往是形式上完成了配对，实质上却没有真正建立起情绪与原因之间的语义联系，从而削弱了系统对真实逻辑关系的辨别能力^[12]。

(2) 生成式模型在复杂推理场景下同样受到现实条件约束。大参数大语言模型虽然具备较强的生成能力，但其内部决策过程并不透明，缺少面向因果判断的显式校验，因此可能给出看似逻辑合理却与具体语境不符的推演结果，并且对算力资源有一定要求。相对而言，边缘侧可部署轻量化模型更符合实际算力条件，但又常常受限于参数规模限制与量化压缩导致的精度下降，在处理长时序上下文和隐含情绪触发源时更容易出现性能衰减^[14]。

基于上述问题，本文不再沿用单纯依赖相关性拟合的处理思路，而是尝试从两个层面改进任务建模：一方面，引入反事实机制，削弱模态之间的虚假相关关联；另一方面，针对小参数视觉语言模型在多方对话推理中的能力欠缺，设计双视角适配器结构，使模型能够分别处理由情溯因与由因推情两类任务，并在可控计算开销下建立更稳定的多模态情绪原因映射。

1.2 国内外研究现状

1.2.1 多模态对话情感与原因抽取研究

近些年，情感计算研究已经由单一文本分析逐步扩展到面向真实对话环境的多模态建模。面对对话中的语义模糊、多方互动和情绪线索分散等特点，仅靠文本分类难以完整刻画情绪形成机制，因此视觉与声学信息持续被纳入该研究方向。与这一变化相伴的是研究目标的调整：学界不再只关注“识别情绪类别”，而是开始进一步讨论“哪些话语或事件触发了该情绪”。这一演进过程与数据集建设密切相关，例如 IEMOCAP (Interactive Emotional Dyadic Motion Capture database) 为早期多模态情绪识别提供了较系统的双人音视频语料^[15]，MELD (Multimodal EmotionLines Dataset) 则把研究场景推进到多方互动环境中，为后续情绪原因分析提供了更复杂的上下文基础^[16]。

围绕这类任务，常见深度学习方法往往结合图神经网络与时序建模模块来梳理对话历史。研究者通过构建异构图网络，尝试分离高频与低频情绪跃迁特征，以维持长程因果链条的连贯性^[17,18,19,20]；同时，一些工作进一步探索端到端图卷积抽取与层级对比学习机制，以缓解密集互动场景下的特征混叠问题并提升配对稳定性^[18]。此外，Tensor Fusion Network、Memory Fusion Network 与 MISA (Modality-Invariant and -Specific Representations) 分别从高阶模态交互、跨时序记忆聚合以及模态共性与特性分解三个角度拓展了多模态情感建模思路，也为后续对话场景中的跨模态表示学习提供了可迁移的方法基础^[92-94]。

与此同时，MECPE 的求解范式也在发生变化。早期方法更偏向判别式映射，重点在于从融合特征中直接预测标签；近来的工作则越来越重视生成式解释，希望模型在给出判断的同时，提供较为完整的归因过程。围绕这一目标，多模态指令微调、适配器微调、提示学习以及错误驱动蒸馏等方法陆续出现^[13,14,21-25,30-31]。这些研究一方面增强了模型对反语、隐含表达和长程依赖的处理能力，另一方面也回应了边缘侧部署时对显存和计算成本的现实约束^[14,23-25]。

在多模态特征交互的拓扑建模方面，图神经网络正与频域分析和多粒度结构设计相结合。引入频域图谱算子后，模型可以同时描述局部瞬时情绪波动与全局语义变化，从而减轻密集互动带来的特征混叠^[27]；借助时序注意力机制和三元组抽取范式，系统又能够在更长的物理距离上保持因果线索的结构化对齐^[19,26]。针对多事件交织的对话流，中枢事件引导和标签约束损失也被用于抑制无关情绪的级联传播^[28-29]。进一步地，多粒度图模型与因果干预机制的结合，使研究开始尝试同时处理模态偏差和位置偏差问题，为跨模态特征对齐建立更稳定的边界^[32-34]。

1.2.2 结构因果模型与多模态去偏研究

虽然多模态情绪原因分析已经取得不少进展，但现有判别式模型普遍仍受到“捷径学习” (Shortcut Learning) 的影响。在噪声较多、分布不稳定的多方会话中，模型容易把偶发的表情变化、局部声学扰动或相邻话语的物理距离，当作判断因果关系的主要依据。结果是系统在训练集上可能表现尚可，一旦场景变化，泛化能力与鲁棒性就会明显下降。

为缓解这一问题，结构因果模型 (Structural Causal Model, SCM) 逐渐被引

入多模态特征分析。借助有向无环图，研究者可以把模态偏见、位置先验等因素显式建模为混淆变量，并进一步分析这些变量如何沿着不同路径影响最终预测。在这一框架下，反事实去偏和因果干预成为常用手段：前者通过构造替代输入观察预测变化，后者则尝试把某些捷径因素从决策路径中剥离出来，以促使模型更多依赖真正有效的语义线索。

针对多模态大语言模型的实证研究也表明，这类模型在处理特征冲突时仍然存在明显的模态偏差。它们往往更容易受到文本先验或局部视觉噪声的影响，从而妨碍客观证据之间的跨模态对齐^[35-37,41-42,46]。此外，在长序列推理和大模型裁判场景下，位置偏差还会进一步扭曲因果判断分布，使模型概率性地偏向物理距离更近的话语^[38-40]。

因此，近年来的研究开始引入更严格的干预与约束机制。DeFacto、CF-MSA等框架把随机掩码、反事实推演和强化式奖励结合起来，在特征层显式估计单模态的自然直接效应，并借助区域敏感的惩罚项，促使模型由表层相关拟合转向更忠实的语义推理^[43-47,76]。与此同时，MuCR 基准和自适应 Logit 调整等方案又把 SCM 扩展到无监督与跨域环境中^[41]；配合扩散模型的数据增强或自回归生成阶段的因果干预，即使在缺少结构化对齐数据的条件下，模型仍有可能保持情绪因果链条推演的稳定性^[44]。

1.3 论文的主要研究内容

针对 MECPE 任务中存在的虚假相关性干扰、大模型因果幻觉以及边缘侧小参数模型推理能力受限等关键问题，本文从理论分析和方法设计两个层面展开研究，主要工作概括如下：

(1) 提出一种基于结构因果模型的反事实多模态去偏框架。针对传统判别式模型过度依赖统计相关、容易陷入“捷径学习”的问题，本文将 Judea Pearl 的结构因果模型 (SCM) 引入 MECPE 任务之中，并据此构建 CMD 框架。该框架把情绪原因识别改写为因果干预过程：在特征层面，通过策略性模态掩码构造反事实场景，估计并削弱模态特定噪声对应的自然直接效应；在输出层面，结合基于 Rubi 机制^[86]的双分支梯度阻断策略，对依赖物理距离的启发式捷径进行约束。实验结果表明，该方法能够较好地削弱模态偏见与位置偏见，使模型更多依赖深层跨模

态语义进行判断。

(2) 设计一种基于混合适配器与双视角认知的轻量化推理框架。针对生成式大模型黑箱性强、小参数模型推理能力不足的问题, 本文提出非对称双流推理结构, 并以冻结的 Qwen2.5-VL-3B 为底座, 动态加载特化 LoRA 适配器, 分别执行“由果溯因”(E-C) 的视觉证据搜索与“由因推果”(C-E) 的社会逻辑推演。同时, 本文进一步构建了错误驱动的思维链蒸馏机制, 通过逆向生成逻辑补全数据, 弥补小模型在模态缺失和复杂语用场景下的推理短板, 从而提升结果的一致性与可解释性。

1.4 论文组织结构

全文由五章构成, 行文安排如下。

第一章为绪论。本章交代情感计算与多模态情绪原因对抽取的研究背景, 说明该问题从单模态识别走向多模态因果分析的演进脉络, 并结合现有工作归纳当前领域面临的主要困难, 包括虚假相关性、大模型幻觉、模态缺失和算力受限等问题。在此基础上, 本章给出本文的研究意义、主要工作及整体结构安排。

第二章介绍与本文相关的技术基础。章节内容包括文本、语音和视觉特征提取所依赖的预训练模型, 如 RoBERTa、HuBERT 与 Vision Transformer; 同时梳理多模态大语言模型及 LoRA 等参数高效微调方法; 最后说明结构化因果模型、因果阶梯、后门准则和中介分析等理论, 为后续去偏方法的提出提供基础。

第三章介绍基于反事实多模态去偏的 CMD 模型。该章首先构建 MECPE 任务的因果图表示, 随后说明两个递进阶段如何实施因果干预: 第一阶段通过特征减法抑制模态特定噪声, 第二阶段借助 Rubi-Focal Loss 进一步削弱位置偏差。最后结合 ECF 数据集实验, 分析该框架在提升鲁棒性方面的作用。

第四章给出基于双视角认知与混合适配器的多模态情绪原因对识别推理框架。该章重点说明如何利用滑动窗口与关键帧采样缓解输入瓶颈, 如何构建 E-C 与 C-E 两条功能不同的适配器推理路径, 以及如何通过错误驱动的 CoT 蒸馏与集合逻辑融合机制, 在较小参数规模下提升复杂因果推理性能。

第五章对全文工作进行总结, 并讨论当前方法在极端长尾分布、动态话题迁移等场景中的局限, 进而对后续可开展的研究方向做出展望。

第二章 论文的理论概要

2.1 引言

本章围绕本文后续模型设计所依赖的技术基础展开说明。内容首先涵盖文本、语音与视觉三类模态对应的预训练模型，明确各类特征表示的来源；随后介绍大语言模型及其多模态扩展形式，以及参数高效微调方法 LoRA；最后结合结构化因果模型的相关理论，为后文反事实去偏方法的提出提供必要的数学和逻辑依据。

2.2 预训练模型

在多模态情绪分析任务中，能否获得质量可靠的单模态表示，直接影响后续跨模态融合与因果推断的效果。本节简要介绍本文使用的基础架构 Transformer 及其在不同模态中的典型变体。

2.2.1 Transformer

Vaswani 等人在 2017 年提出的 Transformer 架构，改变了序列建模长期依赖循环网络的技术路径^[48]。在处理长序列时，传统 RNN 或 CNN 结构容易受到梯度衰减、远距离信息传递效率低等问题的影响。自注意力机制（Self-Attention Mechanism）通过并行方式直接建模序列任意位置之间的关系，从而突破了物理距离带来的限制。对于给定输入特征矩阵，网络首先通过三组可学习参数，将其线性映射到查询（Query）、键（Key）和值（Value）空间，其表达形式如下：

$$Q = XW^Q \quad (2-1)$$

$$K = XW^K \quad (2-2)$$

$$V = XW^V \quad (2-3)$$

得到上述张量后，模型利用查询与键之间的点积衡量全局相关性。为避免内积结果随维度扩大而引起数值过大、梯度不稳定等问题，计算中通常加入缩放因子，并通过 Softmax 完成归一化，最终对值向量进行加权求和：

$$Attention(Q, K, V) = softmax(\frac{QK^T}{\sqrt{d_k}})V \quad (2-4)$$

如果只使用单一注意力头，往往会导致模型表示能力受限。多头注意力通过在多个低维子空间内并行执行上述计算，再将结果拼接映射回原空间，使模型能够同时关注不同层面的依赖关系。也正因为具备这种全局建模能力，

Transformer 逐渐成为自然语言处理及多模态学习中的基础骨架。当前主流的大语言模型（LLMs）和多模态大模型（MLLMs），其底层特征映射与推理流程基本都建立在这一结构之上。




图 2-1 Transformer 结构图

2.2.2 RoBERTa

文本模态构成了对话中情绪逻辑与原因溯源的基础信息来源。双向编码器表示模型 BERT 为上下文预训练提供了通用范式^[50]，但在面对多方、长程对话时，

其表征能力仍存在一定局限。因此, 本文选用 RoBERTa 作为文本特征提取骨干, 以获得更稳定的上下文语义表示^[51]。




图 2-2 BERT 模型结构图

RoBERTa 对 BERT 的一个重要改进, 是将原有静态掩码改为动态掩码。也就是说, 在每一轮数据送入模型时, 掩码位置都会重新采样, 从而使模型在不同训练阶段持续面对新的上下文预测任务。这种做法有助于提升其对低频词、复杂句式以及口语化表达的建模能力。与此同时, RoBERTa 取消了下一句预测目标, 避免了因强制切分文本而造成的语义断裂, 使模型更适合保持长文本与多轮对话中的上下文连续性。再加上更大规模的预训练语料支持, RoBERTa 在处理非结构化口语交互时, 通常能够提供更为充分的文本表示^[50]。

2.2.3 HuBERT

传统声学特征提取方法通常依赖 MFCC 等底层物理属性, 虽然计算方便, 但对语音中的高层语义和副语言信息刻画有限。基于这一考虑, 本文采用 HuBERT (Hidden Unit BERT) 模型作为语音模态的特征提取器^[52]。

与依赖标注文本的传统 ASR 方法^[98]不同, HuBERT 通过 k-means 聚类把连续语音波形映射为离散的“隐藏单元”序列, 再以类似 BERT 掩码语言模型的方式开展预训练。其目标是在部分语音片段被遮蔽的条件下, 根据上下文去预测被遮蔽位置对应的聚类中心标签。换言之, 模型学习的并不是简单的表层声学统计, 而是更稳定的语音内部结构表示, 其损失函数可写为交叉熵形式:

$$L_{HuBERT} = - \sum_{t \in M} \log p(z_t | \tilde{X}) \quad (2-5)$$

这一训练机制使 HuBERT 能够更充分地捕捉语音中的韵律模式、停顿变化和语气转折等副语言线索。对于情绪识别而言，这类信息往往与“反语”“阴阳怪气”或“情绪突然上扬”等现象密切相关，因此能够在一定程度上弥补文本模态对这类信号感知不足的缺点。




图 2-3 HuBERT 模型结构图

2.2.4 Vision Transformer

在视觉模态中，面部微表情通常持续时间短、分布区域小，单纯依赖局部卷积感受野往往难以完整建模。为克服传统卷积神经网络（CNN）在全局关联建模上的局限，本文采用 Vision Transformer（ViT）作为视觉编码骨干^[53]。在视频理解场景中，这一路线随后也被扩展为面向时空联合建模的 ViViT 等结构^[54]。ViT 不再依赖卷积归纳偏置，而是把输入图像划分为一系列固定大小的图块（Patches），并将其展平后映射为序列向量：

$$z_0 = [x_p^1 E; x_p^2 E; \dots; x_p^N E] + E_{pos} \quad (2-6)$$

其中为线性投影矩阵，为保持空间结构而加入的位置嵌入。进入 Transformer 编码器之后，ViT 利用多头自注意力机制在较早阶段就建立不同图块之间的全局联系。对于 MECPE 任务而言，这一点尤为重要，因为情绪线索往往分散在眼部、

嘴角、头部姿态乃至肢体动作等多个区域。借助全局注意力，模型可以在更大范围内联结这些视觉细节，从而形成具有时空感知能力的视觉语义表示，并弥补传统 CNN 在长距离依赖建模方面的不足^[53]。




图 2-4 Vision Transformer 模型结构图

2.3 大语言模型

随着 Transformer 逐步成为统一骨架，多模态大语言模型 (LVLMs) 通过对齐视觉编码器与大语言模型，展现出较强的通用推理能力。本文选用的 Qwen2.5-VL 代表了当前轻量级 LVLM 的重要发展方向^[55]，其架构设计较好回应了视频理解任务中的若干关键困难。

一方面，Qwen2.5-VL 支持原生动态分辨率。传统 LVLM 通常需把输入图像缩放到固定分辨率，这会带来长宽比失真或细节损失，而 Qwen2.5-VL 借鉴类似 NaViT 的处理方式^[56]，把图像划分为数量可变的 Visual Tokens，在尽量保留原始比例的同时保留更多细节。这一点对于捕捉远景中的人物姿态变化或近景中的细微表情尤为关键。另一方面，为更好建模视频中的时序信息，模型采用多模态旋转位置编码 (M-RoPE)^[57]，将位置信息拆分为时间、高度和宽度三个维度。通过这种设计，模型不仅能够识别空间结构，还能更细致地区分不同帧之间的时间跨度，为理解情绪反应的滞后性和延续性提供基础。

多模态大语言模型 (MLLMs) 在情感计算中的应用，也使研究边界由浅层特征分类进一步延伸到社会认知层面^[58-59]。不过，现有系统性评测表明，这类模

型在面对隐含情绪、长时序上下文和复杂人物关系时, 仍然存在明显的推理断层。尽管它们具备一定的上下文学习能力, 但底层机制依然较容易停留在跨模态信号的表层统计拟合上, 难以稳定解耦更复杂的交互意图与心理动机^[60-61]。与此同时, CMU-MOSEI^[95]等开放场景数据集的提出推动了多模态情感分析的标准化评测, 而基于预训练 Transformer 的多模态门控适配方法也说明, 声学线索与文本语义能够在统一预训练框架下实现更细粒度的融合^[96]。

针对这一局限, 计算心理学中的“心理理论”开始被引入模型推理链路之中。相关工作如 EmoLLM^[62]、TMPO^[63]和 SEPM^[64]等, 通过构建置信度引导的粗细粒度推理网络及认知纠偏机制, 要求模型在多方互动中显式表示说话者潜在的信念、意图与立场。这类方法说明, 若要在复杂对话中获得更可靠的情绪理解, 仅仅依靠模态对齐仍然不够, 还需要在推理层面对主体心理状态作出更细致的建模。




图 2-5 Qwen2.5VL 模型结构图

2.4 参数高效微调

在大模型条件下, 直接进行全参数微调不仅计算和存储成本高, 而且容易破坏预训练阶段已经获得的通用知识。LoRA (Low-Rank Adaptation) 作为当前常用的参数高效微调 (Parameter-Efficient Fine-Tuning, PEFT) 方法之一^[65], 其基本思想可以追溯到“内在维度”假设: 即便模型参数规模很大, 针对具体任务所需

的有效更新，往往仍然集中在一个较低维的子空间之中^[66]。

具体来说，LoRA 在冻结原始预训练权重的前提下，引入两个可训练的低秩矩阵来表示权重更新量，其前向传播形式可写为：

$$h = W_0 x + \Delta W x = W_0 x + B A x \quad (2-6)$$

训练过程中，模型只需要更新这两个低秩矩阵，因此可训练参数量通常只占原模型的极小一部分。除参数效率高之外，LoRA 的另一项重要优势在于模块化特征明显。针对不同下游任务，可以分别训练不同的 LoRA 模块，并在推理阶段按需切换或组合。这一点为本文第四章提出的 MoAD 框架提供了直接支持，因为它使得在同一底座模型上按需挂载不同功能的推理适配器成为可行方案。




图 2-6 LORA 微调原理

不过，固定秩分配在面对多模态特征分布偏移时，仍然可能遇到新的表征瓶颈。随着任务异构性增加，统一秩设置的 LoRA 更容易引发不同模态之间的梯度冲突，而这种冲突在深浅层网络中的表现并不一致。

基于这一认识，研究开始转向更灵活的秩分配与适配器组织方式。动态秩分配方法（如 DR-LoRA）结合专家路由频率和激活重要性，自适应调整不同层所使用的低秩空间规模^[67]。这种做法在压缩冗余开销的同时，也有助于减弱次要模态对主导任务的反向干扰。进一步发展的混合适配器框架，则把参数解耦推进到更细粒度层面：通过在指定网络层挂载任务定制化适配器，并配合动态路由共同优化，不同模态或不同子任务的更新过程能够在更大程度上彼此分离^[68-70]。对于边缘侧小参数模型而言，这种非完全共享的优化方式，对于稳定执行复杂多流推理尤为重要。

2.5 结构化因果模型与反事实推理

现有深度学习模型大多建立在独立同分布假设之上，更擅长拟合数据中的表面相关性，却未必能够揭示变量之间真正的因果关系。在多模态任务中，这种仅依赖统计关联的学习方式尤其容易受到环境噪声、位置先验和模态偏好的影响，从而形成“看起来有效、实则脆弱”的虚假相关。一旦测试场景发生变化，模型在分布外 (OOD) 数据上的鲁棒性就可能迅速下降。针对 MECPE 任务中这一根本性问题，本文引入 Judea Pearl 提出的结构化因果模型理论^[71-72]，尝试从数学层面对模型理解多模态数据的方式进行重新组织，使其从相关拟合转向因果推断。

2.5.1 结构化因果模型

结构化因果模型通常可写为一个四元组^[73]。其中， $\mathbf{X}$ 代表外生变量集合 (Exogenous Variables)，用于描述模型无法直接观测、但会影响系统行为的背景因素，如环境噪声或潜在先验； $\mathbf{Z}$ 代表内生变量集合 (Endogenous Variables)，对应模型显式建模的节点，如文本输入、情绪标签或混淆因素； $\mathbf{F}$ 代表结构方程集合 (Structural Equations)，用于规定变量之间的生成关系，即对任意 $z \in \mathbf{Z}$ ，存在函数 f_z 使得 $z = f_z(\mathbf{x}, \mathbf{z}_{\text{pa}(z)})$ 成立，其中 $\mathbf{z}_{\text{pa}(z)}$ 为在因果图中的父节点集合； $P(\mathbf{x})$ 则表示外生变量的概率分布。与只刻画联合分布的传统贝叶斯网络不同，SCM 通过结构方程把“变量受到干预后会如何变化”这一机制显式纳入建模之中。因此，它不仅描述观测分布，还能够支持对外部干预和反事实情形下系统行为的分析^[74]。

2.5.2 因果阶梯与认知层级

Pearl 进一步把智能系统的认知能力概括为三个递进层次，并将其形象地称为“因果阶梯” (The Ladder of Causation) ^[75]。第一层是“关联” (Association)，对应基于观测的预测问题，本质上回答“看到某个现象后，另一事件发生的概率是多少”；当前主流的 BERT 等模型，大体仍停留在这一层。第二层是“干预”

(Intervention)，核心在于引入 do-calculus，回答“如果主动改变某个变量，结果会发生什么变化”，这也是消除虚假相关的关键。第三层是“反事实”

(Counterfactuals)，关注“如果当时没有发生某件事，结果会不会不同”这类回

溯性问题。对人类而言，这种能力与归因、反思和责任判断密切相关；对模型而言，则意味着其推理过程不再停留于表面共现，而开始触及更深的解释层面。本文 CMD 框架的构建，正是建立在这一理论脉络之上。

2.5.3 因果干预与后门准则

在多模态因果图中，经常会出现某一混淆变量同时影响输入与预测结果的情况，例如模态偏见或位置先验既改变模型观察到的特征分布，也左右最终判断。此时，观测到的概率分布会同时混入真实因果效应与虚假统计关联。为了获得更纯净的因果估计，需要依据后门准则 (Back-door Criterion) ^[72]对相关混淆因素进行控制，从而阻断这条非因果路径。如果可以观测并调整混淆变量集合 Z ，那么原本难以直接计算的因果查询，就能够通过分层调整转化为可观测分布上的统计估计：

$$P(Y|do(X)) = \sum_z P(Y|X = x, Z = z) P(Z = z) \quad (2-7)$$

该公式为本研究第三章利用“特征减法”去除模态偏见提供了坚实的数学依据，即通过对混淆因子的边缘化处理，迫使模型学习 X 到 Y 的直接因果链路^[77]。

2.5.4 因果中介分析与效应解耦

为了进一步刻画不同路径对预测结果的贡献，本文引入因果中介分析^[78]。在这一框架下，变量对结果的影响可以拆分为两部分：一部分通过中介变量所承载的真实语义路径传递，另一部分则不经过中介解释，而是沿着偏差捷径直接作用于预测结果。前者通常对应总间接效应 (Total Indirect Effect, TIE)，反映真实语义链路带来的因果贡献；后者对应自然直接效应 (Natural Direct Effect, NDE)，反映位置偏差等因素不经过语义分析而造成的直接影响。根据反事实定义，总效应 (TE) 可以进一步写成两者之和：

$$TE = TIE + NDE \quad (2-8)$$

本文后续去偏方法的核心思想，正是基于这一分解形式：通过构造反事实场景估计 NDE，并把它从总效应中剥离出来，从而削弱虚假捷径对最终推理结果的影响。

第三章 基于反事实多模态去偏的推理框架

3.1 引言

在多模态对话情感分析领域，现有的深度学习范式普遍停留在 Judea Pearl 因果阶梯“关联（Association）”层级^[72]。传统的判别式模型本质上是在拟合条件概率 $P(Y|X)$ ，捕捉数据中的统计共现规律。

但在 MECPE 任务中，仅依赖关联学习往往会把容易观察到的共现线索直接当作因果依据。视觉中的环境噪声可能被误认成有效提示，话语之间的邻近位置也可能被简化为因果判断规则。这样一来，模型虽然能够在训练分布内取得较好结果，却未必真正把握情绪触发背后的语义逻辑。基于这一问题，本章不再单纯增加特征提取的复杂度，而是从建模机制入手，构建基于结构因果模型的反事实多模态去偏框架（Counterfactual Multimodal Debiasing, CMD）。其核心在于把问题由“看到什么就预测什么”转到“控制偏差后再判断因果”，借助 do-calculus 切断混淆因素的后门路径，并通过反事实推理区分真实跨模态语义因果所对应的总间接效应 TIE 与由统计捷径带来的自然直接效应 NDE。

3.2 任务定义

MECPE 任务旨在从多模态对话历史中识别出所有的情绪-原因对。给定一个包含 N 个话语的对话序列 $D = \{u_1, u_2, \dots, u_n\}$ ，其中每个话语 u_i 包含文本 T_i 、声学 A_i 和视觉 V_i 三种模态信息。目标是构建一个函数 $f(D) \rightarrow \{(u_i, u_j) | y_{ij} = 1\}$ ，其中 $y_{ij} \in \{0, 1\}$ 是一个二值标签。当 $y_{ij} = 1$ 表示话语 u_j 是话语 u_i 中所含情绪的触发原因， $y_{ij} = 0$ 表示两者无因果关系。

需要注意的是，根据任务设定，情绪话语 u_i 自身也可能是原因（即 $i = j$ ），

且原因通常位于情绪之前或当时（即 $j \leq i$ ），但这并非绝对约束，本模型保留处理未来原因的能力以适应倒叙等复杂语境。

3.3 因果去偏的理论基石与结构因果模型

本节首先基于结构因果模型 (Structural Causal Model, SCM) 对 MECPE 任务进行数学重构。传统的多模态模型本质上是在拟合观察数据的联合概率分布 $P(Y|X)$ ，这种关联学习机制不可避免地将数据中所有的统计相关性——包括真实的语义逻辑与偶然的噪声捷径——全部吸收为判别依据。为了剥离虚假相关性，本文构建了如图 3-1 所示的因果有向无环图 (Causal DAG)，通过因果干预 (Causal Intervention) 将模型预测的总效应进行解耦。

我们假设模型在推断情绪原因对时的最终预测结果（即总效应，Total Effect, TE）由两部分路径混合而成：一部分是总间接效应（Total Indirect Effect, TIE），代表真实的因果逻辑路径。这是模型基于文本、声学、视觉多模态特征 (M) 之间的深层语义交互，经由因果链条推演出的客观情感诱发逻辑，即 $X \rightarrow M \rightarrow Y$ 的路径，也是我们期望模型学习到的本质映射关系。另一部分则是自然直接效应 (Natural Direct Effect, NDE)，代表混淆变量对预测结果产生的直接干扰，即“捷径学习”路径。

在 MECPE 任务中，这种非语义的捷径主要体现为两个维度：其一是“模态偏差 (Modality Bias)”，如图 3-1(a) 所示，模型可能绕过跨模态交互，直接依赖特定单模态（如视觉中的大笑画面或特定的文本关键词）的表面统计特征进行预测；其二是“位置偏差 (Position Bias)”，如图 3-1(b) 所示，由于数据集中真实原因往往在物理位置上邻近情绪句，模型极易利用相对距离变量 D 直接推断结果 P，从而丧失长距离推理能力。

基于上述定义，本框架的核心去偏逻辑在于：通过引入反事实干预，显式地估计模型在“捷径”路径下产生的 NDE，并从多模态联合推断的 TE 中将其剔除。其核心思想可凝练为如下反事实计算公式：

$$TIE = TE - NDE \quad (3-1)$$

该公式表明，只有从总预测中减去纯粹由偏差驱动的自然直接效应，模型才

能被迫放弃表层捷径，转而依赖深层的语义因果逻辑（TIE）进行决策。




图 3-1 结构因果模型

为了在计算上落实这一设计动机，如图 3-1 所示，本文将去偏过程拆分为两个递进阶段，并分别对应上面两类捷径来源。

阶段一面向特征层的模态偏差，通过掩码特定模态构造反事实样本，显式估计单模态表面信号对预测结果的干扰。可以举一个直观例子：若同一段对话在保留文本后仅遮蔽视觉模态，模型预测结果发生明显变化，那么就说明视觉分支中可能存在被过度依赖的显眼信号；反过来，如果遮蔽语音后结果依然成立，则说明该样本的判断依据未必主要来自声学线索。通过这种“保留其余条件不变、只改变某一模态”的对照方式，模型可以更清楚地区分哪些信息属于真实的跨模态因果证据，哪些只是容易诱导决策的单模态噪声。

阶段二面向输出层的位置偏差，在配对决策阶段额外构建位置感知分支，对单纯依赖相对距离的预测路径进行约束。其设计出发点在于：即使特征层已经做过去偏，模型在最终配对时仍可能因为“最近句通常更像原因”这一数据先验而产生误判。比如，在一个真实原因跨越两轮甚至三轮的样本中，模型可能把紧邻情绪句、但语义联系较弱的话语排到更前面。为抑制这种倾向，本文专门让位置偏差分支去刻画距离捷径，并在训练中削弱这一路径对主分支的牵引，使最终判别更多建立在跨模态语义一致性和上下文因果联系之上。

这两阶段去偏并不是相互重复的：前者回答“模型是否被某一模态中的显眼信号牵着走”，后者回答“模型是否把物理邻近误当成了因果依据”，二者共同构成了 CMD 框架的核心设计出发点。

3.4 方法




图 3-2 基于反事实多模态去偏的情绪原因对抽取模型

CMD 框架通过两个前后衔接的阶段完成去偏。整体来看，它先在特征层面对单一模态的捷径依赖进行干预，再在配对决策层面抑制位置偏差。如图 3-1 所示，整个流程主要包含以下部分：首先，利用 RoBERTa^[50]、HuBERT^[52]和 ViT^[53]分别提取文本、音频和视觉特征，形成基础多模态表示空间；接下来，在 Phase 1 中执行反事实模态去偏（Counterfactual Modality Debiasing），估计并剥离模态特定噪声。该阶段基于结构因果模型（SCM），构建因果图来显式建模模态偏差作为混淆因子 Z_M 。通过反事实干预策略，模型分别计算“总效应（TE）”和“自然直接效应（NDE）”，利用特征减法剔除模态特定的统计噪声，保留跨模态的真实语义交互（TIE）。最后，在 Phase 2 中进行位置感知鲁棒训练，减弱模型对距离启发式规则的依赖。该阶段针对位置偏差 Z_p ，引入基于 Rubi（Robust Bias Mitigation）^[86]的双分支架构。通过构建一个仅依赖相对距离的“捷径分支”，并在训练中采用动态加权的 Focal Loss^[87]对其进行梯度阻断，迫使主分支学习长程语义依赖，而非距离启发式规则。

3.4.1 多模态基础特征提取

本模型首先利用预训练的单模态编码器提取基础表征：文本特征 T_i 采用 RoBERTa 提取，声学特征 A_i 采用 HuBERT 提取，视觉帧特征 V_i 采用 ViT 进行编码。这些异构特征被映射到统一的 d 维隐空间中，表示为 $T_i, A_i, V_i \in \mathbb{R}^d$

3.4.2 多模态去偏模块

在获取文本 (T)、声学 (A) 和视觉 (V) 的模态特征序列后, 模型首先面临异构特征空间的对齐挑战。由于各模态特征通常由不同的预训练编码器提取, 其维度与语义分布存在显著差异。因此, 在时序建模之前, 本研究首先引入模态特定的线性投影层, 将异构特征映射至统一的语义隐空间。

随后, 为了在保留跨模态交互的同时捕捉对话中复杂的时序因果依赖, 模型采用双向长短期记忆网络 (BiLSTM) 作为时序编码的主干。真实对话场景下的情绪触发往往呈现高度的非线性和长距离依赖特征——当前时刻的情绪反应可能源于多轮之前的事件 (前向历史), 也可能依赖于后续的话语解释 (后向未来) 才能被定性。传统的单向循环网络难以有效处理这种跨越长物理距离的因果链条, 且易陷入长序列梯度消失的困境。为此, 本研究通过前向和后向两个平行的时间流对融合后的多模态特征进行全局上下文建模。BiLSTM 通过引入门控机制 (输入门 i_t 、遗忘门 f_t 和输出门 o_t) 来动态调节信息流, 其核心状态更新公式如下:

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \# \quad (3-2)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \# \quad (3-3)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \# \quad (3-4)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t \# \quad (3-5)$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \# \quad (3-6)$$

$$h_t = o_t \odot \tanh(C_t) \# \quad (3-7)$$

在此基础上, 为了构建因果推断所需的总效应 (Total Effect, TE), 本模型摒弃了简单的特征拼接策略, 转而采用加性特征融合 (Additive Feature Fusion) 机制。具体而言, 模型以文本词嵌入为基底, 将经过投影对齐的视觉与声学特征以叠加的方式融入序列, 输入 BiLSTM 从而获得包含完整全局对话历史 (Global Context) 的联合表征 H_{TE} :

$$H_{TE} = BiLSTM(\phi_t(T_i) + \phi_a(A_i) + \phi_v(V_i) + S_{word}) \# \quad (3-8)$$

其中 $\phi(\cdot)$ 表示模态特定的线性映射， S_{word} 为词级基础表征。这一表征代表了模型在“观察”到所有模态数据后的事实推理状态。然而，这种联合表征往往混杂了由单一模态高频特征诱导的自然直接效应 (Natural Direct Effect, NDE)，即“模态捷径”。

为了剥离这种虚假相关性，本框架引入了基于反事实掩码 (Counterfactual Masking) 的干预机制。该机制通过引入二值掩码向量 $M = [m_t, m_a, m_v]$ 控制各模态特征的介入，模拟反事实场景。为了估计某一特定模态 $k \in \{t, a, v\}$ 对预测产生的独立偏差，系统通过强制掩码操作将互补模态特征置零（即仅保留目标模态的掩码位为1，其余为0）。例如，仅由文本模态引发的偏差表征 H_{NDE}^t 、音频偏差 H_{NDE}^a 与视觉偏差 H_{NDE}^v 计算如下：

$$H_{NDE}^t = BiLSTM(\phi_t(T_i) + \mathbf{0} + \mathbf{0} + S_{word})\# \quad (3-9)$$

$$H_{NDE}^a = BiLSTM(\mathbf{0} + \phi_t(A_i) + \mathbf{0} + S_{word})\# \quad (3-10)$$

$$H_{NDE}^v = BiLSTM(\mathbf{0} + \mathbf{0} + \phi_t(V_i) + S_{word})\# \quad (3-11)$$

这种处理并不是为了强化单一模态本身的判别能力，而是把模型对某一模态表层信号的依赖单独暴露出来。也就是说，当其他上下文线索被拿掉之后，模型如果仍给出明显倾向性的预测，那么这一部分输出就可以视为单模态捷径对最终决策造成的额外影响。

为了从总效应中剔除上述偏差并恢复真实的语义因果逻辑（即总间接效应TIE），本研究采用了基于结构因果模型的反事实减法策略。在因果图中，混淆变量导致的数据偏见被建模为对总效应的独立加性贡献。因此，模型在最终的决策层执行线性减法，实现数学上严格的效应解耦：

$$H_{final} = H_{TE} - \alpha \cdot (H_{NDE}^t + H_{NDE}^a + H_{NDE}^v)\# \quad (3-12)$$

其中，为控制去偏强度的超参数。这一运算并不会破坏跨模态协同交互的真实语义结构，而是将由特定模态噪声引发的虚假关联尽量从最终判断中分离出来，使模型在决策时更多依赖多模态间较稳定的语义一致性，而不是单一模态提供的统计捷径。

3.4.3 情绪引导的因果抽取

在经由反事实干预获取去偏后的鲁棒表征 H_{final} 后，模型进入关键的原因抽取与配对阶段。为了模拟人类“由果溯因（Reasoning from Effect to Cause）”的认知心理过程，本研究设计了一个包含显式情绪查询的解码网络。该网络并不将被动接收的特征作为输入，而是主动利用预测出的情绪分布作为“语义探针（Semantic Probe）”，在全局对话历史中检索能够解释当前情感状态的因果线索。

首先，模型基于去偏表征 H_{final} 通过多层感知机（MLP）预测当前话语的情绪概率分布 $P_{emo} \in \mathbb{R}^{n \times C_{emo}}$ （其中 C_{emo} 为情绪类别数）。不同于传统方法仅将此分布用于计算分类损失，本框架将其视为重要的语义先验信息。为了将离散的概率分布转化为连续的特征空间表示，模型引入了一个可学习的情绪嵌入投影层 Emb_{emo} ，将 P_{emo} 映射为高维的情绪语义向量，并将其注入到去偏特征中，形成增强后的情绪查询向量 Q_{emo} ：

$$Q_{emo} = LayerNorm(H_{final} + ReLU(W_e \cdot P_{emo} + b_e)) \quad (3-13)$$




图 3-3 情绪引导的因果抽取

随后，为了进一步提炼情绪查询的语义纯度并聚合上下文信息，模型采用了多头自注意力机制（Multi-Head Self-Attention, MHSA）。该机制允许每个时间步关注序列中的其他位置，捕捉情绪状态在对话流中的演变模式：

$$Q'_{emo} = MHSA(Q_{emo}, Q_{emo}, Q_{emo}) \quad (3-14)$$

在获得增强的情绪查询向量 Q'_{emo} 后，模型的核心任务是从原始的全局上下文 H_{TE} 中定位因果触发语。考虑到因果关系的时序约束（例如，原因通常发生在情绪之前或同时），本研究引入了掩码多头注意力机制（Masked Multi-Head Attention）。

在此机制中， Q'_{emo} 作为查询（Query），而原始的全局上下文 H_{TE} 同时充当键（Key）和值（Value）。为了防止未来的信息泄露干扰因果推断（即避免“果”去关注尚未发生的“因”），我们构建了一个上三角掩码矩阵该注意力过程形式化为：

$$Attention(Q, K, V) = Softmax\left(\frac{QK^T}{\sqrt{d_k}} + M_{mask}\right)V \quad (3-15)$$

$$H_{cause} = MaskedMHSA(Q = Q'_{emo}, K = H_{TE}, V = H_{TE}) \quad (3-16)$$

其中， $\sqrt{d_k}$ 为缩放因子。该机制利用包含丰富情绪语义的查询向量，在受限的上下文窗口中精准检索，动态加权并聚合出能够解释当前情感状态的因果线索表征。随后，检索到的因果线索与原始情绪特征进行拼接融合，并再次通过 BiLSTM 进行平滑处理，最终通过全连接层输出原因概率分布 P_{cause} 。

3.4.4 鲁棒双仿射配对与位置去偏

情绪引导注意力虽然已经能够缩小候选原因的搜索范围，但在最终配对阶段，模型仍然很容易受到位置偏差的影响。训练数据中“原因往往靠近情绪句”的现象，会诱使模型把相对距离当作最省力的判断依据，久而久之便退化为只会寻找最近话语的距离启发器。为避免这一问题，本研究在配对环节额外设置了语义主分支与位置偏差分支：前者依据深层交互信息完成判别，后者专门刻画由距离带来的捷径信号，再借助 Rubi-Focal Loss 对两者进行区分和约束。




图 3-4 鲁棒双仿射配对与位置去偏机制

3.4.4.1 注入概率先验的双仿射语义分支

语义主分支致力于基于深层特征交互计算配对得分为了充分利用第一阶段的判别置信度，模型不仅输入情绪话语表征 h_i 与原因候选表征 h_j ，还引入了显式的概率嵌入。具体而言，系统将第一阶段预测的情绪概率 P_{emo}^i 与原因概率 P_{cause}^j 通过非线性映射 $Emb(\cdot)$ 转化为高维特征，并拼接到对应的上下文表征中。这种设计将“模型有多确信这是个原因”的先验信息直接注入配对网络，增强了判别的鲁棒性。

随后，模型采用双仿射（Biaffine）注意力机制捕捉 (u_i, u_j) 之间复杂的语义依赖。相比于简单的点积或拼接，双仿射变换同时建模了特征的双线性交互与单线性贡献：

$$z_i = MLP_1([h_i; Emb(P_{emo}^i)]) \# \quad (3-17)$$

$$z_j = MLP_2([h_j; Emb(P_{cause}^j)]) \# \quad (3-18)$$

$$S_{ij}^{sem} = z_i^T U z_j + W[z_i; z_j] + b \# \quad (3-19)$$

为了进一步过滤低置信度的噪声配对，本研究在双仿射得分基础上叠加了一个基于概率的 Sigmoid 门控机制。最终的语义分支得分 S_{ij}^{TE} 由语义交互分、门控

截断项以及必要的相对位置编码 E_{dist} 共同构成:

$$S_{ij}^{TE} = S_{ij}^{sem} + \ln(\sigma(MLP_{gate}([P_{emo}^i; P_{cause}^j]))) + E_{dist}(i - j) \# \quad (3-20)$$

这一公式意味着, 候选配对只有在两个条件同时满足时才会得到较高分值: 一是双仿射语义匹配结果足够强, 二是第一阶段给出的情绪与原因预测具有较高置信度。这样可以把低质量、低可信的偶然共现配对压低, 从而提高最终配对结果的稳定性。

3.4.4.2 基于 Rubi-Focal Loss 的梯度截断去偏

为了消除模型对 $E_{dist}(i - j)$ 的过度依赖, 我们构建了一个平行且独立的位置偏差分支。该分支完全屏蔽文本、视觉与声学信息, 仅接收两个话语的相对距离索引 d_{ij} 作为输入, 通过一个简单的多层感知机拟合纯粹由距离捷径带来的“自然直接效应”:

$$S_{ij}^{NDE} = MLP_{bias}(E_{bias}(d_{ij})) \# \quad (3-21)$$

在训练过程中, 本文没有继续采用常见的对抗式去偏方案, 而是选用了基于 Rubi^[86]思想的动态加权 Focal Loss^[87]。该损失并不直接让两个分支相互对抗, 而是依据偏差分支的可预测程度, 动态调节语义主分支实际接收的有效梯度。

$$\mathcal{L} = \sum_{i,j} (1 - \sigma(S_{ij}^{NDE})) \cdot \mathcal{L}_{Focal}(S_{ij}^{TE}, y_{ij}) + \lambda \mathcal{L}_{CE}(S_{ij}^{NDE}, y_{ij}) \# \quad (3-22)$$

该机制的数理逻辑在于: 如果偏差分支能够仅根据距离较为自信地预测正确标签, 则主分支损失对应的权重会相应减小。这意味着模型不会把过多学习能力投入到那些可以靠距离规则轻易判断的样本上, 而是把更多更新集中在必须依赖深层语义互证才能识别的困难样本上。在推断阶段, 模型直接丢弃位置偏差分支, 仅保留去偏后的语义得分输出。换言之, 偏差分支只在训练时承担“暴露捷径”的作用, 而不参与最终预测, 从而尽可能减少距离偏差对判别结果的持续影响。

3.5 实验

3.5.1 实验设置

为检验所提方法在复杂对话与多模态偏差场景下的实际效果, 本文选用 ECF 数据集作为核心评测数据集。该数据集来源于情景喜剧《老友记》, 包含 1400 余段多方对话, 共标注 9794 组情绪-原因对。除文本内容外, 数据还同步提供面部表情与语音语调等非语言线索, 因此能够较为完整地呈现真实会话中的多模态交互。更重要的是, ECF 中同时存在跨距离因果依赖、隐含情绪表达和角色关系交错等情况, 恰好可以用于检验 CMD 框架在抑制模态捷径和位置偏差方面是否具有稳定效果。

在评价指标方面, 本研究严格遵循 MECPE 任务的标准评测协议。对于模型预测的情绪-原因对集合 $\mathcal{P}_{pred}$ 与人工标注的真实标签集合 $\mathcal{P}_{gt}$, 判定预测正确的唯一标准是: 预测的情绪话语索引 i 与原因话语索引 j 必须同时与真实标签完全匹配。基于此严格匹配准则, 我们采用精确率 (Precision, P)、召回率 (Recall, R) 以及调和平均数 F_1 分数作为量化指标。具体的计算公式定义如下:

$$P = \frac{|\mathcal{P}_{pred} \cap \mathcal{P}_{gt}|}{|\mathcal{P}_{pred}|} \quad \#(3-23)$$

$$R = \frac{|\mathcal{P}_{pred} \cap \mathcal{P}_{gt}|}{|\mathcal{P}_{gt}|} \quad \#(3-24)$$

$$F_1 = \frac{2 \cdot P \cdot R}{P + R} \quad \#(3-25)$$

其中, $|\cdot|$ 表示集合的基数 (即集合中元素的数量)。 P 衡量了模型预测结果的准确性, 即在所有预测出的因果对中有多少是真实的; R 衡量了模型的覆盖能力, 即在所有真实存在的因果对中有多少被模型成功检出; F_1 则综合反映了模型的整体性能。在本实验的所有对比分析中, 我们将重点关注 Pair- F_1 指标, 以此作为衡量模型最终去偏效果与推理鲁棒性的核心依据。

表 3-1 ECF 数据集的统计数据

	对话	语句	情感语句	情绪原因对
训练集	1001	9966	5577	7055

验证集	112	1087	668	866
测试集	261	2566	1445	1873

3.5.2 对比模型

为保证比较结果尽量客观，本文选取了覆盖不同技术路线的代表性基线模型，既包括传统两阶段方法，也包括统一框架、图网络模型以及生成式大模型。

其中，流水线与统一框架方法主要选取 MECPE-2Steps^[8]和 UniMEEC^[11]。前者代表较早期的标准两阶段提取思路，后者则体现了基于共享提示学习的统一建模方案。

在图结构建模与全局交互方向上，本文选用 MultiCauseNet^[26]和 M3F^[25]作为对照。二者分别侧重时序图注意力建模与全局记忆式特征聚合，能够反映该类方法在 MECPE 任务上的代表性表现。

在生成式模型方面，本文比较了序列生成框架 GMEC^[88]，并进一步纳入在特定提示词下进行零样本测试的 GPT-4o 与 Gemini-2.5-Pro，用以观察通用大模型在该任务上的适应情况。

表 3-2 MECPE 任务实验结果

方法	模态	情感识别 F_1	原因识别 F_1	配对识别 F_1
MECPE-2Steps	Text+Audio	79.17	70.27	53.48
	Text+Video	79.03	72.18	53.21
	Text+Audio+Video	79.16	70.27	53.20
Hilo	Text+Audio	78.01	72.18	53.95
	Text+Video	78.03	72.01	53.64
	Text+Audio+Video	79.35	72.28	55.45
UniMEEC	Text+Audio+Video	-	59.18	54.61
MULTICAUSE NET	Text+Audio+Video	-	65.12	55.12
GMEC	Text+Audio	79.21	69.13	55.64

	Text+Video	79.26	69.75	56.50
	Text+Audio+Video	79.41	70.12	55.64
	Text+Audio	-	-	57.47
M ³ F	Text+Video	-	-	57.45
	Text+Audio+Video	-	-	55.96
LLMs	GPT-4o	61.19	33.78	15.24
	Gemini 2.5pro	75.84	56.56	34.01
	Text+Audio	81.06	70.79	56.38
Ours	Text+Video	77.68	71.71	54.62
	Text+Audio+Video	80.94	72.73	57.97

3.5.3 实验结果

从表 3-2 可以看出, CMD 在 ECF 的核心 MECPE 任务上取得了当前最优结果。其 Pair F₁ 达到 57.97%, 高于 MECPE-2Steps 的 53.20%, 也略高于此前表现最好的 M³F 的 57.47%。这一结果说明, 在引入反事实去偏之后, 模型对情绪与原因之间真实关联的把握更加稳定。

还需要指出的是, 即便不经过任何微调, 直接调用 GPT-4o 这类大参数模型进行零样本预测, 所得结果仍明显落后于 CMD。这样的差距说明, 参数规模本身并不能自动转化为对多模态因果关系的可靠建模能力。对于 MECPE 这类任务而言, 如果缺少针对偏差路径的显式约束, 模型仍可能被表层共现信号牵引, 难以稳定区分真正的因果触发与统计巧合。

表 3-3 和表 3-4 进一步给出了 MECPE-Cat 任务上的细粒度比较结果。该任务不仅要求模型抽取情绪-原因对, 还要求同时判断对应的情绪类别。结果表明, CMD 在综合指标上同样保持优势: 在 Text+Audio+Video 设置下, 六分类加权平均 F₁ (Weighted-avg.6) 达到 40.87%, 较 HiLo 的 33.04% 提高 7.83 个百分点; 四分类指标 (Weighted-avg.4) 达到 45.08%, 同样优于现有对比方法。整体来看, CMD 的优势并不集中在单一类别, 而是在多情绪条件下都表现出更稳定的能力。

以具体类别为例, CMD 在“惊喜”上的提升最为明显, F₁ 达到 59.10%, 显著高于 HiLo 的 43.55% 和 MECPE-2Steps 的 40.64%。这一结果说明, 反事实去偏

机制确实有助于缓解由夸张表情或声学突变带来的误判。传统模型容易把这类信号直接等同于某一情绪类别，而 CMD 在去除单模态捷径后，能够更多依赖上下文逻辑还原情绪的真实含义。类似现象也出现在“愤怒”类别上，模型同样取得了 42.55% 的较好结果。

表 3-3 MECPE-Cat 任务细粒度结果

方法	模态	愤怒	恶心	恐惧	喜悦	伤心	惊喜
MECPE-2Steps	Text+Audio	26.30	0.46	0.5	39.62	22.73	41.35
	Text+Video	22.68	0.19	0.36	38.55	20.58	39.99
	Text+Audio+Video	25.08	0.09	1.01	38.49	22.36	40.64
Hilo	Text+Audio	28.85	1.77	3.51	41.38	23.50	43.67
	Text+Video	30.02	13.07	5.13	41.60	26.92	41.78
	Text+Audio+Video	29.17	1.68	3.12	42.58	25.1	43.55
CMD	Text+Audio+Video	42.55	0	0	48.42	28.57	59.10

表 3-4 MECPE-Cat 加权平均结果

方法	模态	Weighted-avg.6	Weighted-avg.4
MECPE-2Steps	Text+Audio	30.47	33.15
	Text+Video	28.57	31.11
	Text+Audio+Video	29.62	32.24
Hilo	Text+Audio	32.39	35.09
	Text+Video	33.61	35.68
	Text+Audio+Video	33.04	35.81
CMD	Text+Audio+Video	40.87	45.08

并且我们可以观察到，长尾类别仍然是当前任务中的主要难点。受 ECF 类别分布极不均衡的影响，各模型在“恶心”和“恐惧”等低频类别上的得分普遍偏低。虽然 HiLo 在个别数值上略有优势，但整体召回仍然有限。这说明，小样本和长尾场景下的因果推理问题并未随着整体性能提升而自动解决，后续仍需结合数据重采样、代价敏感学习或更细粒度的先验约束继续改进。

总体来看，CMD 通过在特征层和决策层分别实施因果干预，有效削弱了多模态数据中的虚假相关。由此带来的收益不仅体现在整体抽取精度的提高上，也

体现在复杂情绪类别和跨模态交互场景下更稳定的判别表现上。

3.5.4 消融实验与干预机制验证

为了探究 CMD 框架中各个组件的贡献，我们进行了消融实验。

表 3-5 消融实验结果

MCF	M.A.	P.B.	P.G.	E F ₁	C F ₁	P F ₁
w/o	w/	w/	w/	80.84	71.08	57.17
w/	w/o	w/	w/	80.62	71.55	57.17
w/	w/	w/o	w/	80.96	72.17	53.10
w/	w/	w/	w/o	81.06	70.88	56.82
w/	w/	w/	w/	80.94	72.73	57.97

如表 3-5 所示，位置去偏机制 (Rubi) 的作用最为明显：当移除基于 Rubi-Focal Loss 的位置偏差分支后，模型的 Pair F1 由 57.97% 降至 53.10%，下降了 4.87 个百分点。这说明，如果不对距离捷径施加显式约束，模型仍容易回到“优先匹配邻近句子”的简化策略。换言之，Rubi 机制并不是附加性的细节优化，而是在长距离因果识别中帮助模型摆脱位置偏差、转向语义判断的重要组成部分。

多模态反事实融合 (MCF) 的去噪验证：当移除基于加性融合的单模态反事实屏蔽机制后，原因提取 (Cause Extraction) 的 F1 分数从 72.73% 下降至 71.08%。这表明阶段一的因果干预有助于过滤诸如“突然的音量变化”或“偶然的笑脸”等容易造成误导的单模态表面信号，使最终提取到的原因更贴近对话语境中的真实触发因素。




图 3-5 多模态去偏对表征的影响

与此同时，我们还探究了多模态去偏对表征的影响。如图 3-5 所示，左图是去偏前的特征分布，真实情绪原因对（红点）与无关对（蓝点）大量重叠，说明模型仍会受到表面相关性的干扰。右图是去偏后的特征分布，红点与蓝点已经明显分开，形成了相对独立的聚类。虽然高维特征映射到低维空间后出现局部纠缠属于常见现象，但整体分布的变化仍说明，去偏机制确实削弱了多模态数据中的噪声偏差，帮助模型学到更清楚的分类边界。




图 3-6 位置去偏样例 1




图 3-7 位置去偏样例 2

为了检验位置去偏机制是否真正发挥作用，本文提取了因果抽取模块中的注意力权重，并将其绘制为热力图。图 3-6 和图 3-7 展示了两个具有代表性的长距离情绪原因对样本。在图 3-6 所示的 Doc 5、Pair 10<-8 中，情绪话语位于 U10，真实原因位于 U8。可以看到，模型对物理上更接近的干扰话语 U9 仅分配了 0.020 的注意力，而把更高的权重 0.25 集中到真实原因 U8 上。图 3-7 也呈现出相近现象：当情绪发生在 U3 时，模型没有把注意力停留在相邻的 U2，而是把最高权重 0.30 分配给两轮之前的 U1。结合这两个样本可以判断，经过去偏训练后，模型对“距离最近即更可能为原因”的简单启发式依赖有所减弱，开始更多依据上下文语义去识别长程因果线索。

3.5.5 案例研究

为了更具体地观察模型在复杂分布下的判断方式，本文进一步选取推断阶段的两个案例，对比不同模型对候选原因的概率分配情况，如图 3-8 所示：

案例 A 主要用于说明位置偏差被削弱后的变化。在 Dialogue 99 中，真实原因话语与对应情绪话语并不相邻，二者相隔两个轮次。基线模型受距离惩罚影响较大，仅给出 0.3607 的匹配概率，因此未能识别出这组长程因果对。加入位置

去偏机制后，CMD 将该因果对的联合概率提升到 0.5569，使其越过判定阈值。这个例子表明，经过专门训练后，模型对相邻话语的默认偏好有所收敛，面对跨轮次原因时也能保持一定识别能力。

案例 B 反映的是语义干扰更强时的情况。在 Dialogue 660 中，紧邻情绪句的话语带有较强的表层误导性，基线模型因此把较高概率分配给这一干扰项，而对真正的远距离原因关注不足。引入 CMD 后，模型对干扰项的偏好被压低，对真实原因的排序位置也有所提升。虽然在这一样本上，模型最终仍未完全跨过 0.5 的判定阈值，但概率分布的变化至少说明，反事实去偏机制能够在一定程度上修正由局部共现和表层语义造成的误导。换言之，对于这类语义纠缠较强的案例，CMD 虽未完全解决问题，却已经把判断方向从“邻近且显眼的干扰项”拉回到更可能的真实原因上。




图 3-8 案例分析

3.6 本章小结

本章围绕 CMD 模型的设计思路、关键推导和实验结果展开讨论。模型在结构上结合了双向 LSTM 的时序建模、基于零掩码的模态反事实构造以及双分支 Rubi-Focal 损失，以分别处理模态偏差和位置偏差问题。实验与消融结果表明，这些设计确实改善了模型对虚假相关的敏感性，使其在 ECF 场景下较少依赖距离捷径或单一模态中的显眼信号。换句话说，CMD 的作用不只是带来数值提升，更重要的是让模型的判断依据从表层相关性逐步转向跨模态语义和因果关联本身。

第四章 基于双视角认知与混合适配器的推理框架

4.1 引言

上一章提出的 CMD 框架已经证明，借助结构因果模型的显式干预，可以在判别式范式下减弱多模态数据中的偏差信号。但对 MECPE 而言，研究目标不应停留在“判别是否成立”这一层面，更关键的是让模型能够给出相对完整的因果解释。传统判别式模型通常把问题拆分成若干离散子步骤，虽然便于训练，却不容易保留连续的推理过程。另一方面，多模态大语言模型具备较强的端到端生成能力，但在边缘侧场景中，大参数规模带来的计算负担和黑盒特征同样限制了其实用性。

基于上述矛盾，本章提出一种基于双视角认知与混合适配器的推理框架，即 Mixture-of-Adapters via Dual-perspective (MoAD)。该框架不再单纯依赖扩大模型参数来换取性能，而是通过任务解耦的方式，对 Qwen2.5-VL-3B 挂载非对称 LoRA 适配器，使模型分别承担“由情绪回溯原因”和“由原因推演情绪”两类互补推理。与其继续沿着“大模型参数更大、结果自然更好”的路径推进，不如把有限算力用于组织更清晰的推理流程。换言之，本章尝试把 MECPE 从以分类为中心的处理方式，推进到以结构化推理生成为核心的处理方式。

4.2 任务重构

在 MoAD 框架下，本文将 MECPE 重新表述为带有条件约束的结构化文本生成任务。给定多模态对话历史 H 和当前查询 Q ，模型不再输出单一概率值，而是直接生成便于解析的 JSON 序列。这样做的目的，一是减少传统流水线中的额外后处理，二是把模型的推理结果固定到统一格式中，便于后续统计、比对与错误分析。具体输出结构如下：

$$\{\text{"Emotion": } i, \text{"Cause_Index": } j\}$$

这种设计使模型必须在生成结束标记之前先完成内部推理，再给出最终结构化结果，而不是在后处理中再去拼接各类中间判断。同时，统一的输出形式也便

于对模型结果做批量解析和量化评估。

4.3 方法

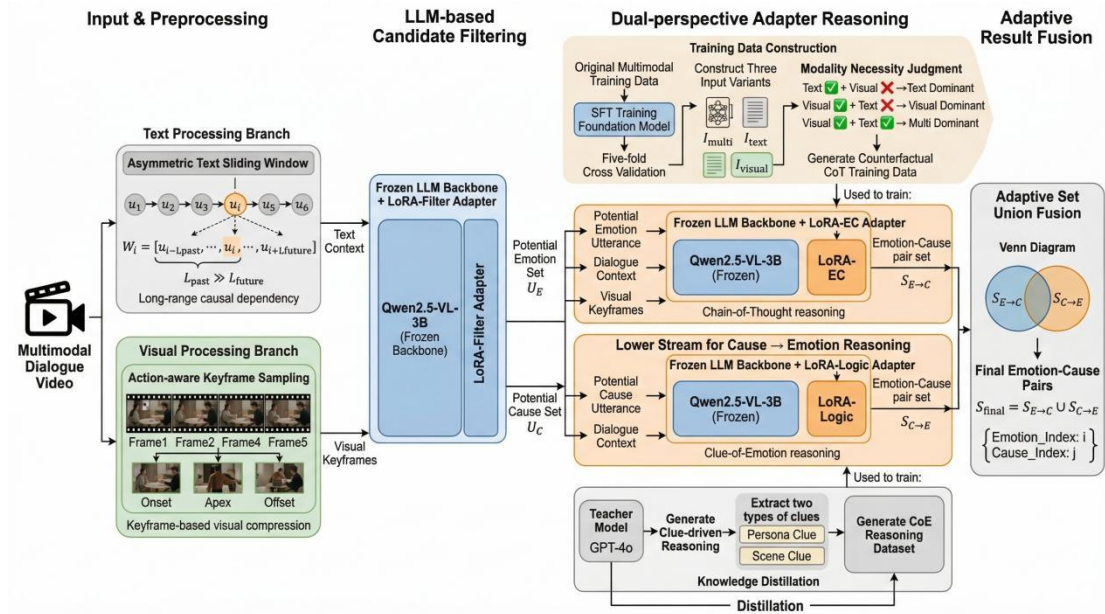


图 4-1 基于双视角认知与混合适配器的推理框架

如图 4-1 所示，MoAD 主要由四个阶段构成：输入预处理、基于 LLM 的候选过滤、双视角适配器推理，以及最终的集合逻辑融合。其核心思路可以概括为“认知解耦”，即在共享同一底座模型的前提下，让不同 LoRA 模块分别承担不同方向的因果推理任务。这样做的目的，不是简单堆叠模块，而是尽量避免单一路径同时处理全部信息时出现的表征拥挤与推理混淆。

具体而言，本章针对传统多模态模型在长程因果推理中计算代价高、生成式大模型又容易出现因果幻觉的问题，构建了 MoAD 联合推理框架。该框架同时强调两点：一是把任务拆解到更清晰的认知子过程之中，二是通过参数高效路由，把有限算力集中用在真正需要深推理的环节。

在底座模型选择上，本文采用兼顾多模态理解能力与部署成本的 Qwen2.5-VL-3B。该模型支持原生动态分辨率和时间位置编码，能够较好保留视频帧中的空间尺度信息与时序变化，因而适合作为边缘侧多模态推理的基础模型。结合 ms-swift^[91]提供的训练与显存优化能力，本文进一步将原本复杂的端到端推理流程拆分为两条相互补充的认知路径：一条面向“由果溯因”的证据检索，另一条面向“由因推果”的语义推演。这样处理的关键意义，在于让同一底座模型在不

显著增加参数负担的前提下，分别学习两类不同方向的因果判断偏好。

为了把这两类认知子任务稳定地迁移到模型参数中，本文利用了 ms-swift 对标准多模态对话微调格式的原生支持。在数据构造时，不再采用松散的文本拼接方式，而是统一封装为由 System、User 和 Assistant 组成的消息结构。System 负责给出任务约束、输出要求以及必要的推理边界，User 负责组织多模态输入及其时间顺序，Assistant 则对应模型需要学习的结构化输出。在这一格式下，模型不只是学习“答案是什么”，还要学习“答案是如何得出的”。具体来说，训练样本会要求模型先给出中间推理信息，再输出最终的原因索引和情绪标签，从而把“先分析、后结论”的推理习惯固化到训练过程中。与传统把多模态信息直接摊平成长文本输入的做法相比，这种结构化组织方式更有利于稳定控制输出格式，也更便于后续统计模型在不同推理阶段的错误来源。对本文而言，这一点尤其重要，因为第四章关注的不只是最终配对是否正确，还希望观察模型在不同认知路径下究竟遗漏了什么、依赖了什么，以及两条路径在什么位置开始出现分歧。

整个 MoAD 框架的数据流转管线包含四个递进的核心阶段：

1. 整个 MoAD 的输入处理流程由四个递进环节组成。首先，针对长对话和多模态输入带来的冗余信息，系统通过非对称采样策略进行预处理，尽量保留关键语境而压缩无效内容。随后，利用轻量级 LoRA-Filter 对候选空间进行初筛，再交由 E-C 与 C-E 两条专门化适配器分别完成推理，最后通过集合逻辑融合形成统一输出。

2. 在候选过滤阶段，LoRA-Filter 充当高召回率的路由器。它并不追求在这一阶段给出非常精细的判断，而是优先从全量对话图谱中筛出值得进一步分析的候选项。这样可以显著压缩后续推理的搜索空间，把计算预算留给真正复杂的因果配对。

3. 进入精细推理阶段后，系统并行挂载两类任务特化的 LoRA 模块。E-C 流偏重从已观察到的情绪反应回溯潜在触发源，C-E 流则偏重从候选原因出发推断可能造成的情绪结果。二者各自通过针对性数据进行微调，因此在认知侧重点上存在明显差异，也正因如此，它们能够形成互补而非重复的判断。

4. 在输出端，MoAD 没有采用单一路径直接裁决的方式，而是采用“并集保全”的自适应集合融合策略。系统通过结构化解析与去重，在不额外引入新参数

的前提下，尽量保留两条推理路径各自发现的有效因果对。对于 MECPE 这类以漏检代价较高的任务，这种做法比过早收缩到单一路径更稳妥。

因此，MoAD 的优势并不来自某一单独模块的极端强化，而是来自多级处理环节之间的衔接：前端负责减负，中段负责分工，后端负责互补。通过这种组织方式，系统在受限算力条件下仍能保持较好的推理透明度与可复现性。

4.3.1 多粒度上下文路由与时空特征采样

当包含大量多方互动的多模态对话被直接送入小参数模型时，最突出的问题往往不是单步计算错误，而是输入过长带来的信息拥挤。若对所有模态一律采用静态截断，很容易在压缩冗余信息的同时把真正关键的因果链条一并切断。为此，MoAD 在输入端设计了与双视角推理相适配的多粒度文本窗口和视觉采样策略。

1. 认知解耦的多粒度文本窗口策略

考虑到 MECPE 任务在候选初筛与深度推理两个阶段对上下文范围的需求并不相同，本文将文本窗口设计与双视角架构对应起来。在基于 LoRA-Filter 进行粗召回时，系统保留全局对话文本，并拼接当前话语的局部视觉与声学特征，使路由模块能够在不丢失整体情节的前提下，先对潜在情绪触发点完成高召回筛查。进入精细推理阶段后，E-C 流与 C-E 流再采用不同的滑动窗口：前者以当前情绪话语为锚点，保留更深的历史上下文，以便执行“由果溯因”的回溯判断；后者则以候选原因为锚点，纳入适量后续反馈，以便检验该事件是否在后续对话中真正引发了相应情绪。

对于 E-C 流而言，窗口设计强调“向后看”。也就是说，系统以当前情绪话语为锚点，保留更深的历史上下文，同时尽量避免未来信息干扰当前回溯判断。这样的设置更符合“先看到结果，再追查原因”的推理方向，也更容易把注意力集中到可能真正触发情绪的既有事件上。

$$W_{E \rightarrow C} = [u_{i-L_{past}}, \dots, u_i] \#(4-1)$$

在设计 C-E 流（由因推果）的窗口时，我们以潜在原因候选为锚点，C-E 专家采用包含后续反馈的推演窗口，其窗口定义如下：

$$W_{C \rightarrow E} = [u_{j-L_{local}}, \dots, u_j, \dots, u_{j+L_{future}}] \#(4-2)$$

与之相对, C-E 流采用更具前瞻性的窗口设计。系统以潜在原因候选为锚点, 观察该事件在后续交互中是否引发与预期一致的情绪反应。这样可以帮助模型判断某个候选项究竟只是偶然出现, 还是确实在后续语境中发挥了情绪触发作用。

2. 基于 CLIP 语义差分的关键帧提取与时空映射

为了在尽量降低视觉 token 开销的同时保留情绪突变时刻, 本文没有采用均匀抽帧, 而是提出基于 CLIP^[89]语义差分的“起始-高潮-结束”三帧采样机制。具体而言, 系统先逐帧提取视频片段的全局语义嵌入, 再计算相邻帧之间的余弦相似度变化。当相似度出现显著下降时, 可视为面部表情或肢体动作发生了明显切换, 据此形成候选关键帧序列。相比把全部视频帧等距离送入模型, 这种做法更关注情绪真正发生变化的位置, 而不是平均保留所有时刻的视觉信息。它实际上把视觉输入从“连续铺开”改成了“围绕关键转折点组织”, 更符合情绪事件本身具有突发性和阶段性的特点。对多方对话视频而言, 这种差分式采样还能减少背景镜头、姿态稳定段和静止表情段对模型注意力的占用, 使有限视觉容量更多服务于真正与情绪转折相关的片段。

在此基础上, 系统分别取动作变化序列的首帧和尾帧作为 Onset 与 Offset, 并将中间最具代表性的时刻视为 Apex。与简单的均匀采样相比, 这种做法更容易抓住情绪真正发生变化的关键瞬间, 同时也压缩了大量静态或过渡帧带来的冗余开销。换言之, 模型看到的不是一段被平均切分的视频片段, 而是一组围绕情绪变化过程精简后的视觉快照。配合 Qwen2.5-VL-3B 的动态分辨率处理能力, 三帧输入既保留了细粒度表情信息, 也减少了无效视觉计算, 从而在有限算力下兼顾视觉质量与推理效率。

4.3.2 基于 LoRA-Filter 的视觉-语义路由

在将多模态对话历史输入参数受限的边缘侧多模态大语言模型 (如 Qwen2.5-VL-3B) 时, 首先需要处理超长上下文带来的计算负担与信息密度之间的矛盾。若对所有模态统一做静态截断, 不仅容易切断长程因果链, 还会把与任务无关的视觉噪声一并保留下来。基于此, MoAD 在输入端设置了与不同推理阶段相匹配的上下文路由策略: 在候选初筛阶段, 系统将全局对话文本与当前目标话语的局部视觉、声学特征联合输入, 使路由模块能够兼顾剧情主线和当前情绪

线索，从而以较低显存开销完成高召回过滤。

进入双视角精细推理阶段后，C-E 流与 E-C 流采用不同的滑动窗口配置。由于情绪原因关系通常具有回溯性，E-C 流以当前情感话语为锚，构建“深历史、浅未来”的非对称窗口，把主要注意力放在过去语境中可能的触发事件上。C-E 流则以潜在原因候选为锚，保留更充分的后续反馈，用来判断该事件在后续短程交互中是否真正诱发了预期情绪。这样的窗口差异并非形式变化，而是服务于两条路径不同的推理目标。

Prompt Example for Multimodal Emotion-Cause Recognition	
[System]	You are an expert in multimodal emotion and cause recognition. Analyze the target utterance using dialogue context and visual cues.
[Scene]	Setting: coffeehouse Topic: humorous conversation
[Visual_Keyframes]	
[Dialogue]	ID 1 Chandler: "... totally naked ..." (TARGET) ID 2 All: "Had that dream" ID 3 Chandler: "there is a phone..." ID 4 Joey: "Instead of...?" ...
[Task]	Determine: Emotion (0/1) Cause (0/1)
[Output]	{ "is_emotion": 0/1, "is_cause": 0/1 }
[Target]	{ "is_emotion": 0, "is_cause": 1 }

图 4-2 视觉语义路由适配器训练提示词

在视觉模态的时空特征提取方面，为了在控制视觉 token 开销的同时尽量保留情绪变化的关键瞬间，本文没有采用均匀抽帧，而是使用基于动作感知的“起始-高潮-结束”三帧采样策略。对于每一个话语区间，系统只保留最能代表情绪变化过程的三个视觉快照：起始帧用于捕捉表情或动作的初始变化，高潮帧承载主要视觉情绪线索，结束帧用于判断情绪是否延续或回落。借助 Qwen2.5-VL 的动态分辨率处理能力，这种做法能够在不过度增加计算负担的前提下较好保留关键表情细节，并把三帧在原视频中的时间顺序映射到模型的位置编码中，使模型能够感知情绪变化的大致时序。

4.3.3 双视角适配器推理机制

多模态因果推理通常包含两类方向不同的判断过程：一类是根据已出现的情绪反应回溯触发原因，另一类是从候选事件出发推测其可能引起的情绪结果。若

在同一组可训练参数中同时拟合这两类目标，容易出现梯度更新方向不一致、能力相互牵制的问题。基于这一考虑，MoAD 在冻结 Qwen2.5-VL-3B 底座参数的前提下，并行挂载两个相互独立的 LoRA 适配器，分别对应 E-C 与 C-E 两条推理路径。这样做的主要目的，是把原本混杂在同一参数空间中的两类认知任务适度分开，使模型能够在较小显存开销下形成更稳定的分工。

4.3.3.1 E-C 流：基于模态必要性的反事实溯源

LoRA-EC (Emotion-to-Cause) 适配器的核心任务是执行“由果溯因”，即在给定目标情绪话语后，回溯触发该情绪的上下文线索。为避免模型只输出一个难以解释的标量概率，本文将 E-C 流的微调目标重构为带有结构约束的条件生成任务。模型不仅需要给出最终的原因索引，还要按照预设格式组织中间推理信息，使训练过程更贴近“先检索证据，再形成判断”的路径。

Prompt Example for Emotion-Cause Recognition (E→C)

[System] 'You are an expert in multimodal emotion-cause recognition. Given a TARGET utterance (with provided visual keyframes) and a short dialogue context, identify which preceding utterance(s) most likely caused the TARGET emotion, and provide the TARGET's emotion category.'

[Visual_Keyframes]



These images correspond to the TARGET utterance. Images should be shown as actual visual placeholders (not file paths).

[Dialogue Transcript] (The line marked with '>>> TARGET <<<' corresponds to the provided visual keyframes)

[History] ID 9 | Rachel: "Hi , uh , nothing . That horrible woman just took my machine ."

[History] ID 10 | Ross: "Was your basket on top ?"

[History] ID 11 | Rachel: "Yeah , but , there were no suds ."

[History] ID 12 | Ross: "So ?"

[History] ID 13 | Rachel: "Well , you know , no suds , no save ."

TARGET <<< ID 14 | Ross: "No suds ? Excuse me , hold on a second . That is my friend machine ."

[Future] ID 15 | Woman: "Hey , hey , hey , her stuff was not in it ."

[Future] ID 16 | Ross: "Hey , hey , hey , that is not the rule and you know it ."

[Task] List the CAUSE utterance ID(s) from the PRIOR context that most directly triggered the TARGET emotion. If multiple causes, list them in ascending order. If none, ran empty list. Provide the emotion label for the TARGET (choose from: anger, joy, sadness, surprise, fear, disgust, other).

[Output Format] {"cause_ids": [id1, id2, ...], "emotion": "<label>"}

[Target Output] {"cause_ids": [9], "emotion": "anger"}

图 4-3 由情溯因适配器交叉验证训练提示词

为了获取高质量的因果推理依据，我们首先设计了一套基于五折交叉验证的反事实模态消融策略。具体而言，系统将训练数据进行五折划分，针对每个对话样本构建三种输入变体：完整多模态输入、掩码视觉特征输入以及掩码文本特征输入。通过对比底座模型在不同输入变体下的预测结果来执行因果必要性判定：若模型在掩码某一模态时预测失败，而在完整输入下预测成功，则严格判定该缺失模态为因果对成立的“必要主导条件”（如视觉主导或文本主导）；若缺一不可，

则判定为双模态协同主导。

Prompt Example with Multimodal CoT for Emotion-Cause Recognition	
[System]	You are an expert in multimodal emotion-cause recognition. Given a TARGET utterance (with visual keyframes) and dialogue context, identify the most likely causal utterance(s) and determine the TARGET emotion.
[Visual_Keyframes]	
[Dialogue Transcript]	(The line marked with '>>> TARGET <<<' corresponds to the provided visual keyframes) [History] ID 1 Chandler: 'Hey !' TARGET <<< ID 2 Joey: 'Hey ! So Estelle lined up a bunch of auditions for me tomorrow and I will have my health insurance back in no time .' [Future] ID 3 Chandler: 'That is great , but should not you be on the toilet right now ?' [Future] ID 4 Joey: 'What ? !'
[Task]	Identify CAUSE utterance ID(s) from prior context. Return [] if none. Classify TARGET emotion. Options: anger, joy, sadness, surprise, fear, disgust, other.
[Output Format]	<think> ... reasoning ... </think> { "cause_ids": [id1, ...], "emotion": "<label>" }
[Model Output]	<think> The TARGET utterance explicitly conveys positive news about upcoming auditions and regaining health insurance, indicating a strong positive emotional state. There is no prior utterance that triggers this emotion; instead, the emotion originates from the TARGET itself. </think> { "cause_ids": [2], "emotion": "joy" }

图 4-4 由情溯因适配器多模态反事实推理训练提示词

基于上述反事实判定结果，本文结合 ms-swift 的多模态微调格式，构造了包含中间推理步骤的结构化 CoT 指令数据集。数据封装采用 System、User 与 Assistant 三元消息结构：User 负责输入对齐后的关键帧与带锚点的对话历史，Assistant 则输出可解析的 JSON 序列。为降低模型直接跳到结论的倾向，在输出最终的原因索引（cause_ids）与情绪标签（emotion）之前，训练样本要求模型先生成简要的多模态推理依据，并用<think></think>标签约束中间思路。这样处理的目的，不是追求冗长解释，而是把“先分析、后结论”的推理顺序更稳定地写入微调过程。

该类认知解耦与结构化逻辑生成的计算思路，与多模态大模型在深层推理任务中的演进方向是一致的。AlgoPuzzleVQA 与 MMMU 等基准评测表明，边缘侧轻量模型在处理抽象因果关联时，如果过度依赖端到端的隐式概率映射，容易落入表面特征拟合带来的偏差^[79,80]。为使推理链路更加清楚，多模态思维链（Multimodal Chain-of-Thought, MCoT）逐步被引入到多模态推理框架之中^[81]。近期的 Generative Visual CoT (GVCoT) 等工作进一步说明，在输出最终判断之前交替执行视觉定位与文本反思，有助于缓解异构模态之间的表征错位问题^[82,83]。

针对 3B 级别模型在隐晦语境中的推理不足, 本文进一步引入误差驱动思维链蒸馏机制作为补充。SuperCorrect 等工作表明, 利用更强教师模型对学生模型的历史错误进行监督, 并通过偏好优化方式调整推理模板, 有助于提升小模型的纠错与反思能力^[84]。同时, ThinkRL-Edit 等研究也提示, 在训练中引入更细化的链路偏好分组和奖励设计, 有利于减弱模型对预训练统计先验的机械依赖^[85]。本文在此基础上将相关思想用于小参数多模态模型的训练组织, 目标并非夸大其能力上限, 而是尽量提高其在复杂任务中的推理稳定性与输出一致性^[55]。

4.3.3.2 C-E 流: 基于多任务辅助增强的隐式线索推理

LoRA-Logic (Cause-to-Emotion) 适配器对应的是“由因推果”的推理任务, 即从给定原因出发, 判断其在特定对话场景中可能引发的情绪结果。受 CoE^[90] 框架启发, 本文认为这类推理不能只依赖字面语义是否相近, 而需要综合角色身份、交互关系和场景语境等隐性线索。尤其在多方对话中, 同一句话是否会引发情绪反应, 往往取决于说话双方的关系、当时的交际氛围以及事件在上下文中的位置。对 3B 级别的小模型来说, 这部分能力通常是薄弱环节, 因此有必要通过额外训练进行补强, 而不是寄希望于模型在推理时自动补全全部常识。

Prompt Example for Cause-to-Emotion Reasoning (C→E)

[System]	You are an expert in causal reasoning for dialogues. Given a potential cause utterance with visual evidence and its surrounding context, identify which future utterances are emotionally triggered. (These correspond to the POTENTIAL CAUSE utterance.)
[Visual_Keyframes]	
[Context Window]	(Analyze the impact of the line marked '>>> POTENTIAL CAUSE <<<') >>> POTENTIAL CAUSE <<< [ID 1] Chandler: "Alright , so I am back in high school , I am standing in the middle of the cafeteria , and I realize I am totally naked ." [Future] [ID 2] All: "Oh , yeah . Had that dream ." [Future] [ID 3] Chandler: "Then I look down , and I realize there is a phone ... there ." [Future] [ID 4] Joey: "Instead of ... ?" [Future] [ID 5] Chandler: "That is right ." [Future] [ID 6] Joey: "Never had that dream ."
[Task]	Determine whether the potential cause utterance triggers emotional reactions. If yes, list the IDs of the triggered utterances If none, return an empty list
[Output Format]	{"triggered_emotion_ids": [id1, id2, ...]}
[Model Output]	{"triggered_emotion_ids": [3, 4, 5]}

图 4-5 由因推果适配器多模态反事实推理训练提示词

为此, 系统借助教师模型提供的常识先验, 对训练数据进一步构造多维辅助认知任务, 并与核心的 C-E 推演任务共同训练。这样做并不是简单扩充样本量,

而是有意识地把角色、场景和情绪演化之间的隐含关系编码到适配器参数之中。本文主要引入了以下两类辅助任务：

1. 说话人身份识别任务要求模型根据全局对话历史判断当前情绪话语的归属。该任务的作用，在于促使模型建立角色身份与情绪表达习惯之间的对应关系，从而在后续推断中更准确地区分不同人物的语气变化和反应方式。

Prompt Example for Speaker Identification	
[System]	You are an expert in dialogue understanding. Given multimodal context including visual cues, persona descriptions, and dialogue history, identify the speaker of the target utterance.
[Visual_Keyframes]	
[Personas]	Julie: A sweet-natured paleontologist and Ross's former colleague. She is calm, emotionally stable, and expresses herself in a gentle and polite tone. Rachel: A fashion-conscious and emotionally expressive character. She tends to show vulnerability and hesitation in emotionally complex situations.
[Context]	Rachel: "Um, ok, uh, oh god, um, when you and Ross first started going out, it was really hard for me..." Rachel: "I just see how happy he is, and how good you guys are together..." >>> TARGET UTTERANCE <<< [ID ?]: "Thanks." Julie: "Hey, listen, would you like to go to a movie sometime or something?"
[Task]	Identify the speaker of the target utterance based on: - visual cues - persona consistency - dialogue context
[Output Format]	{"speaker": "Julie or Rachel"}
[Model Output]	{"speaker": "Julie"}

图 4-6 说话人识别辅助任务提示词示例

2. 场景感知的角色扮演任务则要求模型在给定人物设定和场景背景的前提下，预测更符合语境的后续回应。相比直接学习标签，这种任务更强调情绪表达背后的社会化约束，因此能够增强模型对场景氛围与互动边界的把握。

Prompt Example for Scene-aware Role-playing	
[System]	You are an expert in dialogue understanding and role-playing. Given a character persona and the multimodal scene context, generate a response that is consistent with the character's speaking style and appropriate to the social context.
[Visual_Keyframes]	
[Persona]	Character: Janice Speaking Style: expressive, exaggerated tone, emotionally reactive
[Context Window]	(Generate the next response for the character based on the dialogue and scene)
[History]	Janice: So did you do it ? Janice: Did you make your deposit ? Chandler: Yeah ! yeah ... The hard part is over ! >>> TARGET RESPONSE (Janice) <<<
[Task]	Generate the next response for the character. Requirements: - Stay consistent with the given persona - Reflect the scene context if relevant - Produce a natural and contextually appropriate reply
[Output Format]	Janice: <generated response>
[Model Output]	Janice: That is not the hard part, honey! The hard part is what comes next, I mean aren't you worried about the results?

图 4-7 角色扮演辅助任务提示词示例

训练时, 本文将这些辅助任务与核心 MECPE 数据一并用于 LoRA-Logic 的联合指令微调。其目的在于把“线索整合、角色代入、情绪归因”这一较为复杂的语用理解过程, 逐步内化为适配器中的稳定参数偏好, 而不是完全依赖推理阶段的临时猜测。

在最终推演阶段, C-E 流采用严格的 Schema 约束解码策略。模型接收被锚定的候选原因及其前瞻性上下文窗口作为输入, 直接输出结构化 JSON 结果, 而不再额外生成冗长解释文本。这样既保留了微调阶段学到的逻辑约束, 又减少了推理时不必要的显存和时间开销, 更适合边缘侧部署需求。更重要的是, 这种做法把推理阶段的自由度控制在可管理范围内, 降低了模型因长文本生成而偏离目标任务的风险, 使其更专注于围绕候选原因本身完成情绪后果判断。对于小参数模型而言, 收紧输出空间本身就是一种有效的稳定化手段, 因为它能够减少模型在开放式生成中出现无关扩写、格式漂移和逻辑跳跃的情况, 也便于后续统一做程序化解析与误差统计。

4.3.4 自适应集合逻辑融合

在推理阶段, 系统分别获得了来自 E-C 流 (由果溯因) 的结构化预测集合 $S_{E \rightarrow C}$ 与来自 C-E 流 (由因推果) 的预测集合 $S_{C \rightarrow E}$ 。为了充分发挥双视角认知的异构互补性, MoAD 框架在输出端摒弃了容易造成信息损耗的单一输出或硬投票机制, 转而采用了一种“并集保全 (Union for Recall)”的自适应集合融合策略。我们将最终的输出集合严格定义为双流预测结果的并集, 即:

$$S_{\text{final}} = S_{E \rightarrow C} \cup S_{C \rightarrow E} \#(4-3)$$

这种融合策略之所以合理, 可以借助认知心理学中的“双重加工理论”来理解。人在处理复杂社会情绪归因时, 往往同时依赖快速的直觉判断和较慢的逻辑分析。MoAD 中的 E-C 流更接近前者, 它擅长捕捉局部、直观、感知性较强的信号, 如表情突变、声学起伏和明显的语义冲突; C-E 流则更接近后者, 偏向利用先验常识、人物关系和语境结构进行审慎推演。前者更像“先看到异常, 再追查源头”, 后者更像“先确认事件, 再评估后果”。需要说明的是, 这里并不是把心理学术语机械套到模型上, 而是借这一理论解释双路径分工为何能够成立: 一条路径优先处理显性的感知证据, 另一条路径负责补足较慢的语境推演。二者各自都不是完

整答案，但把它们放在同一框架中协同工作，可以在很大程度上缓解单一路径容易出现的偏科问题，也使得模型在处理显性情绪样本和隐性社会语用样本时都能保留一定判断能力。

在多模态对话场景中，这两类认知路径各有盲区。如果只取二者交集，许多只被其中一条路径识别到的真实因果对就会被提前排除；而并集策略虽然会带来一定噪声，却能最大限度保留互补信息。对这一点，直观地看会更清楚：有些样本主要靠表情或语调突变暴露因果线索，E-C 流更容易先发现；另一些样本几乎没有明显外显情绪，却在人物关系、反讽表达或语用冲突中埋着触发点，这类情况往往需要 C-E 流补上。

对于 MECPE 这类任务，漏掉关键原因对后续整体语义链条的破坏，通常要比多保留少量次要候选更严重。因此，从任务需求出发，采用并集保全比单纯追求高精度更符合实际。换个角度看，这一策略本质上是在优先保证“不要漏掉值得进一步分析的因果候选”，再通过后续的结构化约束和去重机制控制误报范围，而不是一开始就过于激进地缩小输出集合。特别是在多方对话中，同一原因往往可能通过不同模态、不同轮次、不同人物视角被间接显露出来，若过早采用严格裁剪，系统就会损失掉原本非常有价值的补充证据。

4.4 实验

4.4.1 数据集及评估指标

本节实验沿用第 3.5.1 节所使用的 ECF 数据集，并采用 Precision (P)、Recall (R) 和 F1 score (F_1) 作为主要评价指标。同时，为保证横向比较的一致性，基线模型设置也与第 3.5.1 节保持一致。

表 4-1 ECF 数据集的统计数据

	对话	语句	情感语句	情绪原因对
训练集	1001	9966	5577	7055
验证集	112	1087	668	866
测试集	261	2566	1445	1873

4.4.2 实验设置

本文实验统一采用 Qwen2.5-VL-3B 作为底座模型。虽然该系列还提供 7B、72B 等更大规模版本，但 3B 模型在保留较强多模态理解能力的同时，对硬件资源的要求明显更低。在 BF16 精度下，其推理显存需求约为 6GB 至 8GB，更符合边缘侧部署场景。全部微调与适配器训练均基于 ms-swift 完成，以保证训练过程的效率和显存利用率。

4.4.3 实验结果

表 4-2 MoAD 在 ECF 数据集上实验结果

方法	情感 F_1	原因 F_1	配对 F_1
MECPE-2Steps	79.16	70.27	53.20
HiLo	79.35	72.28	55.45
UniMEEC	-	59.18	54.61
MULTICAUSENET	-	65.12	55.12
GMEC	79.41	70.12	55.64
M3F	-	-	55.96
GPT-4o	61.19	33.78	15.24
Gemini-2.5 pro	75.84	56.56	34.01
MoAD(3B)	85.27	77.41	58.98

表 4-2 给出了 MoAD 在 ECF 数据集上的整体结果。可以看到，MoAD (3B) 在情感识别 F_1 、原因识别 F_1 和情绪原因对配对 F_1 三个指标上分别达到 85.27%、77.41%和 58.98%，其中配对 F_1 较 HiLo 和 GMEC 分别提升 3.53 和 3.34 个百分点，取得了对比方法中的最好结果。需要强调的是，这一结果是在 3B 级别底座模型上获得的，说明本文提出的双视角适配与集合融合机制能够在较小参数规模下有效组织 MECPE 推理流程，而不是单纯依赖更大的模型容量来弥补推理不足。与此同时，MoAD 相较零样本状态下的 GPT-4o 和 Gemini-2.5 Pro 也保持了明显优势，表明在该任务中，面向领域结构的专门化训练仍然比直接调用通用模型更有效。结合与 MECPE-2Steps、HiLo 等方法的比较可以发现，性能收益主要来自

对 E-C 与 C-E 两条推理路径的协同建模, 这也从实验上验证了本文方法在复杂情绪原因对抽取场景中的有效性。

表 4-3 MECPE-Cat 加权平均结果

方法	模态	Weighted-avg.6	Weighted-avg.4
MECPE-2Steps	Text+Audio	30.47	33.15
	Text+Video	28.57	31.11
	Text+Audio+Video	29.62	32.24
Hilo	Text+Audio	32.39	35.09
	Text+Video	33.61	35.68
	Text+Audio+Video	33.04	35.81
CMD	Text+Audio+Video	60.97	68.2

与此同时, 我们探究了不同细粒度情感的情绪原因对识别效果, 实验结果如表 4-3 和表 4-4 所示。从表 4-3 可以看到加权平均结果, 本文方法在 Weighted-avg.6 和 Weighted-avg.4 (除去恶心和恐惧情感) 上分别达到 60.97%和 68.20%, 较最优基线分别提升 27.93 和 32.39 个百分点, 说明其优势并非来自个别类别, 而是体现在整体细粒度情绪分布上的稳定提升。

表 4-4 MECPE-Cat 任务细粒度结果

方法	模态	愤怒	恶心	恐惧	喜悦	伤心	惊喜
MECPE-2Steps	Text+Audio	26.30	0.46	0.5	39.62	22.73	41.35
	Text+Video	22.68	0.19	0.36	38.55	20.58	39.99
	Text+Audio+Video	25.08	0.09	1.01	38.49	22.36	40.64
Hilo	Text+Audio	28.85	1.77	3.51	41.38	23.50	43.67
	Text+Video	30.02	13.07	5.13	41.60	26.92	41.78
	Text+Audio+Video	29.17	1.68	3.12	42.58	25.1	43.55
CMD	Text+Audio+Video	62.21	12.24	40.0	70.81	59.38	66.67

表 4-4 展示出更加细粒度的单类情感类别表现, 愤怒、恐惧、喜悦、伤心和

惊喜上的改进尤为明显，其中喜悦和惊喜分别达到 70.81%和 66.67%，表明多视角推理对于显性情绪线索和跨轮触发关系具有较强的建模能力。即便在样本相对稀疏、识别难度更高的恶心类别上，本文方法也取得了 12.24%的结果，仍明显高于多数基线。总体来看，这组结果说明 MoAD 的性能提升具有较好的类别普适性，能够在不同细粒度情绪上保持更稳定的原因对抽取能力。

4.4.4 消融实验

表 4-5 单视角与多视角表现分析

方法	P	R	F ₁
E-C (SFT only)	49.58	47.62	48.58
C-E (SFT only)	57.63	40.93	47.87
E-C	56.38	57.16	56.77
C-E	56.69	47.92	51.94
MoAD	52.83	66.74	58.98

表 4-5 结合图 4-6 展示了 MoAD 中两条推理路径的单独表现及融合后的结果。其中，E-C (SFT only) 和 C-E (SFT only) 表示仅对底座模型进行直接监督微调，不使用本文提出的数据训练优化方案；E-C 和 C-E 则是在相同推理方向下进一步加入本文方案后的结果。这样的对比设置有助于区分性能提升究竟来自推理视角本身，还是来自训练优化策略与双视角融合的共同作用。

从单路径结果看，加入本文数据训练优化方案后，两条推理流的性能均有提升。E-C 的 F₁ 由 48.58%提高到 56.77%，提升 8.19 个百分点，且 Precision 和 Recall 同步改善；C-E 的 F₁ 由 47.87%提高到 51.94%，提升 4.07 个百分点，其中 Recall 由 40.93%提升到 47.92%，说明该方案有效缓解了直接 SFT 下模型偏保守、漏检较多的问题。与此同时，C-E 在 Precision 上仍保持相对优势，而 E-C 在 Recall 上更强，表明两种视角在证据利用方式和决策偏好上依然存在稳定差异。

在此基础上，融合后的 MoAD 进一步将 Recall 提升到 66.74%，最终获得 58.98%的 F₁。图 4-6 中的互补性分析也支持这一结论：两条路径共有 719 个共同命中的正确样本，此外 E-C 和 C-E 还分别额外覆盖了 352 个和 179 个对方未命中的正确样本。虽然并集保全策略会带来一定的精度回落，但它换来了更高的

样本覆盖率和整体 F1，说明 MoAD 的收益并非简单来自结果叠加，而是来自“训练优化增强单流能力”与“双视角融合扩大覆盖范围”的共同作用。这也从侧面证明了本文提出的数据训练优化方案和双视角设计都是必要的。




图 4-6 双视角推理流的性能边界与认知互补性分析

4.4.5 性能分析

为了评估 MoAD 在边缘侧或算力受限设备上的部署可行性, 本文进一步统计了整条推理管线的端到端物理开销, 结果如表 4-6 所示。评测在单张 GPU 环境下进行, 并以参数规模更大的 Qwen2.5-VL-7B 作为对照模型。主要比较指标包括峰值显存占用、单样本平均时延以及每个输出 token 的生成耗时。这样设置的目的, 是从实际部署角度判断 MoAD 是否只是理论上有效, 还是在资源受限条件下同样具备落地可能。

从显存结果看, 7B 模型的峰值显存达到 16.09GB, 而采用 3B 底座的 MoAD 完整管线稳定在 7.44GB。后者已经可以运行在主流 8GB 显存设备上, 这意味着多模态因果推理不再必须依赖高规格训练卡才能落地。对于需要在普通实验室设备或轻量部署环境中运行的场景, 这一点具有比较直接的工程价值。

在推理延迟方面, MoAD (3B) 的单样本平均耗时为 14.71 秒, 低于 7B 模型的 17.70 秒, 说明小参数底座在多次前向传播组成的级联流程中仍具有明显开销优势。虽然 3B 模型的单 token 生成速度略慢于 7B 模型, 但两者都处于可接受范围内, 且差距没有大到影响实际使用。从部署角度看, 端侧系统更关心的是整条推理链路能否稳定完成, 而不仅仅是单一步骤是否更快; 在这一点上, MoAD

的级联流程并没有带来不可接受的时延负担。考虑到 MoAD 本身还包含候选过滤、双路径推理和结果融合等多个环节，这样的延迟水平已经表明其在复杂流程下仍具备较好的响应效率。综合来看，MoAD 在保持较高抽取性能的同时，也兼顾了实际部署所需的资源约束，这意味着它并不是单纯追求论文指标的设计，而是具备一定工程可行性的方案。

表 4-6 部署开销与推理效率对比

模型参数量	Peak VRAM	Avg Latency	TPOT
7B	16.09GB	17.70s	66.28ms
3B	7.44GB	14.71s	83.49ms

4.4.6 案例分析

为了更直观地说明双适配器的互补作用，本文选取验证集中的一个典型案例进行分析。如图 4-7 所示，该对话片段围绕 Joey 提出的不合时宜建议展开，并在后续引发了多位角色的不同情绪反应。两条推理路径在这一案例中给出了不同但互补的关注重点。

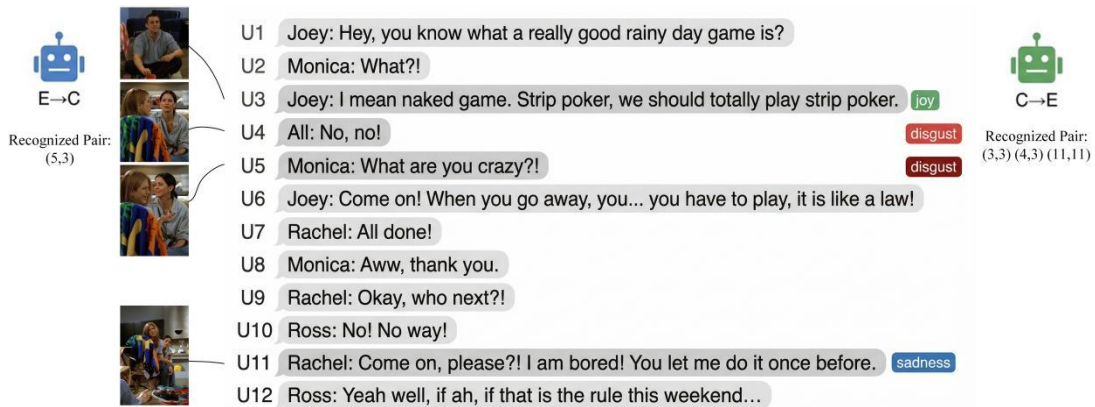


图 4-8 双适配器互补案例

E-C 适配器准确识别出因果对(5, 3)。在第 5 轮对话中，Monica 明确表现出“厌恶 (Disgust)”情绪；结合关键帧中的表情信息，E-C 流能够以这一显著情绪爆发点为锚，向前回溯并定位到第 3 轮 Joey 的不当提议。这里的关键在于，模型并不是仅凭文本中某个高频词进行匹配，而是把表情变化、语气冲突和上下文事件放在一起理解。这说明，E-C 路径在处理由突发情绪反应主导的溯因任务时，对显性多模态线索具有较强敏感性。

相比之下, C-E 适配器则单独捕捉到了(4, 3) 和(11, 11)等多组因果对。以(4, 3)为例, 它不是从情绪句反推原因, 而是把第 3 轮 Joey 的发言视为核心事件, 进一步推演其在后续交互中可能引发的群体反应。借助微调阶段注入的角色和场景常识, 模型判断这一提议突破了社交边界, 因此会导致后续的拒绝和反感。这种判断方式更接近人类在社交场景中的常识推演: 即便某一时刻尚未出现非常强烈的外显情绪, 也可以根据事件本身的语境含义预判后续可能出现的情绪走向。该案例说明, C-E 路径在处理需要社会语境推断的样本时, 能够补足 E-C 路径不易覆盖的部分。

4.4.7 错误分析

为了探究 MoAD 架构在极端多模态对话场景下的性能边界与失效机理, 本节对系统输出的异常预测结果执行了误差分析。底层解构结果表明, 在当前的计算约束与并集路由策略下, 模型存在两类确定性的结构误差。

首先是滑动窗口截断导致的长程认知物理断层, 此类失效高度集中于物理轮次跨度极大的因果链路。为控制计算开销与注意力矩阵的显存峰值, 模型输入端部署了固定长度的上下文滑动窗口。这一工程限制直接对多模态上下文实施了硬截断。在对话 142 的特征张量中, Monica 在第 13、14、15 轮次密集爆发的厌恶与愤怒情绪 (如“I am Joan Collins.”), 其真实的物理触发锚点均指向第 1 轮次的核心陈述 (“...I just had sex with somebody...”)。该因果链的物理轮次跨度达到 12 至 14, 直接越过了滑动窗口的保留阈值。网络在自回归生成当前情绪节点的推演路径时, 前置的原因锚点已被强制移出输入序列。自注意力算子无法对不可见的上下文执行特征对齐与内积计算。该类漏判本质上是输入张量残缺造成的物理级断层, 而非模型内部逻辑推演的梯度耗散。

另外主要的误差来源是专家流单向过拟合与并集策略的噪音继承。部署的双向并集融合机制在拓宽召回边界的同时, 无损继承了单一专家流的特征噪音。例如 C-E 专家流在处理高唤醒度情绪节点时, 暴露出严重的“捷径学习”缺陷。在对话 1193 中, Chandler 突发的愤怒反应 (ID 8: “I am strong ! I will show you !”) 被 C-E 流强行归因于前置相邻轮次 Ross 的常规回应 (ID 7)。在对话 331 中, Ross 的愉悦突变 (ID 6) 被错误回溯至其自身前置的提问 (ID 3)。底层逻辑表

明，C-E 专家流对特定的高频交互词汇产生了过拟合。在缺乏严密跨模态语义蕴含的约束下，算法强制将高唤醒度情绪标签与物理距离邻近的话语节点执行了因果绑定。由于系统未在并集层后沿部署独立的反事实校验模块，此类由单向特征溢出引发的因果幻觉被全量透传至最终预测结果，构成了对整体精确率的刚性侵蚀。

4.5 本章小结

本章围绕大模型在 MECPE 任务中部署成本高、而小模型推理深度不足这两类问题，提出了基于双视角认知与混合适配器的 MoAD 框架。该方法先通过非对称采样和 Filter 压缩输入与候选空间，再分别构建 E-C 与 C-E 两条推理路径，并通过集合逻辑融合整合两者结果。整套设计并没有把性能提升寄托在单一模块的极端强化上，而是强调前端减负、中段分工和后端互补之间的衔接。实验表明，在仅使用 3B 底座模型的条件下，MoAD 依然在 ECF 上取得了 58.98% 的 Pair F_1 。这说明，围绕任务结构重组推理流程，再配合参数高效适配，小模型同样可以在复杂多模态因果推理任务中取得较稳定的结果。

第五章 总结与展望

5.1 本文总结

本文围绕多模态对话场景下的情绪原因对抽取 (MECPE) 任务展开研究, 讨论重点放在两个彼此相关的问题上: 一是如何减弱模型对表层统计相关性的依赖, 二是在参数规模受限的条件下, 如何保持较为可靠的多模态因果推理能力。围绕这两个问题, 本文先分析了基于结构因果模型与反事实去偏的情感溯源方法, 随后又考察了基于轻量级多模态大模型的双视角推理与残缺模态补偿机制, 并在此基础上形成了较为完整的技术路线。

首先, 本文提出了反事实多模态去偏框架 CMD, 用来处理 MECPE 任务中较为突出的统计捷径问题。针对模态偏差, CMD 通过对特定模态实施掩码来构造反事实输入, 据此估计并剥离模态特有的偏置信号; 针对位置偏差, 模型结合双分支位置感知策略, 削弱对物理邻近关系的过度依赖。经过这一处理, 模型的判断依据不再主要停留在表层相关线索上, 而是更多转向跨模态语义与因果关联本身。这一部分工作的意义在于, 它为后续更复杂的推理过程提供了相对干净的输入基础, 也说明在 MECPE 场景中, 仅靠相关性匹配往往是不够的。

其次, 本文进一步提出了基于双视角推理与混合适配器 (Mixture-of-Adapters) 的 MoAD 框架, 以回应大模型推理开销偏高、通用生成路径不够稳定, 以及小参数模型深层推理能力有限等问题。该模型以 Qwen2.5-VL-3B 为统一底座, 在不同阶段加载任务特化的 Adapter, 并行执行 E-C (由情绪回溯原因) 与 C-E (由原因推演情绪) 两条互补路径, 再通过集合逻辑对结果进行汇总。对于模态缺失或线索残缺的情况, 本文又引入误差驱动的思维链蒸馏机制, 让小模型在训练过程中逐步学习较完整的推理依据, 而不是仅记住最后的标签输出。实验结果表明, 在不依赖更大参数规模的前提下, 这一路线仍然能够取得较稳定的性能提升。

综合前述两部分工作可以看到, 本文并不是分别处理“去偏”和“推理”两个孤立问题, 而是尝试把虚假相关性削弱、双路径逻辑校验以及参数高效微调放进同一条研究链路中加以考察。最终模型在 ECF 数据集上的实验结果显示, 这种组

合式思路是可行的。在仅使用 Qwen2.5-VL-3B 作为底座模型的条件 下，MoAD 取得了 58.98% 的 Pair F1。对本文而言，这一结果更重要的意义不 只是数值上的提升，而在于说明小参数模型经过针对性的任务拆解和结构化 训练后，仍然能够在复杂的多模态因果推理任务中保持较强竞争力。

5.2 展望

本文围绕多模态对话场景下情绪原因对抽取问题提出了一套递进式处理 思路，相关实验结果也说明这些方法在公开数据集上能够发挥作用。不过， 真实交互环境中的语境变化、角色关系和模态缺失情况都比标准数据集更 复杂，现有工作仍有若干需要继续推进的地方。结合本文实验中暴露出的 局限，后续研究至少可以从以下两个方面展开：

第一，模型在极端长尾样本和标签分布不平衡条件下仍有进一步优化的 空间。以本文使用的 ECF 数据集为例，“害怕 (fear)”和“厌恶 (disgust)” 等类别的样本数量明显偏少，实验中这类标签的溯源表现也更容易波动。 归根结底，这并不是单一模型结构能够完全弥补的问题，而与训练样本覆盖 范围不足直接相关。因此，在多模态标签极不均衡的场景下，如何结合小 样本学习、数据重加权，或者更审慎地引入生成式增强方法来补充稀缺类 别，仍然是后续需要认真处理的方向。

第二，现有模型对长程多方对话中的“话题变迁 (Topic Shift)”还缺少显 式建模能力。在真实多人对话中，情绪爆发往往并不是由某一句紧邻话语 单独触发的，而可能是在多轮交互、话题切换和角色立场变化中逐步积累 出来的结果。本文提出的双视角推理与去偏机制已经能够改善局部因果识 别，但对于更长跨度的主题演进轨迹，刻画仍然不够充分。后续如果能够 把显式话题追踪、长程记忆建模或层级对话结构表示进一步纳入 MECPE 框 架，模型对跨轮次、跨话题情感原因对的识别能力有望得到更稳定的提 升。

参考文献

- [1] Xi Z, Chen W, Guo X, et al. The rise and potential of large language model based agents: A survey[EB/OL]. 2023. arXiv:2309.07864.
- [2] Picard R W. Affective computing[R]. Massachusetts Institute of Technology, Media Laboratory, Perceptual Computing Section, 1995.
- [3] Poria S, Cambria E, Bajpai R, et al. A review of affective computing: From unimodal analysis to multimodal fusion[J]. Information Fusion, 2017, 37: 98-125.
- [4] Xia R, Ding Z. Emotion-cause pair extraction: A new task to emotion analysis in texts[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 1003-1012.
- [5] Baltrušaitis T, Ahuja C, Morency L P. Multimodal machine learning: A survey and taxonomy[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2018, 41(2): 423-443.
- [6] Poria S, Majumder N, Mihalcea R, et al. Emotion recognition in conversation: Research challenges, datasets, and recent advances[J]. IEEE Access, 2019, 7: 100943-100953.
- [7] Poria S, Majumder N, Hazarika D, et al. Recognizing emotion cause in conversations[J]. Cognitive Computation, 2021, 13(5): 1317-1332.
- [8] Wang F, Ding Z, Xia R, et al. Multimodal emotion-cause pair extraction in conversations[J]. IEEE Transactions on Affective Computing, 2023, 14(3): 1832-1844. <https://doi.org/10.1109/TAFFC.2022.3226559>
- [9] Huang Z, Zhao J, Jin Q. ECR-Chain: Advancing Generative Language Models to Better Emotion-Cause Reasoners through Reasoning Chains[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI-24). 2024: 6288-6296. <https://doi.org/10.24963/ijcai.2024/695>
- [10] Wang F, Ma H, Xia R, et al. SemEval-2024 Task 3: Multimodal Emotion Cause Analysis in Conversations[C]//Proceedings of the 18th International Workshop on Semantic Evaluation (SemEval-2024). Association for Computational Linguistics, 2024: 2039-2050. <https://doi.org/10.18653/v1/2024.semeval-1.277>
- [11] Hu G, Zhu Z, Hershcovich D, et al. UniMEEC: Towards Unified Multimodal Emotion Recognition and Emotion Cause[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Association for Computational Linguistics, 2024: 5248-5261. <https://doi.org/10.18653/v1/2024.findings-emnlp.302>
- [12] Bao Y, Ma Q, Wei L, et al. Multi-Granularity Semantic Aware Graph Model for Reducing Position Bias in Emotion Cause Pair Extraction[C]//Findings of the Association for Computational Linguistics: ACL 2022. Association for Computational Linguistics, 2022: 1203-1213. <https://doi.org/10.18653/v1/2022.findings-acl.95>
- [13] Hu Z, Wang L, Lan Y, et al. LLM-Adapters: An Adapter Family for Parameter-Efficient Fine-Tuning of Large Language Models[C]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing.

- Association for Computational Linguistics, 2023: 5254-5276.
<https://doi.org/10.18653/v1/2023.emnlp-main.319>
- [14] Yang Y, Dong X, Qiang Y. MSE-Adapter: A Lightweight Plugin Endowing LLMs with the Capability to Perform Multimodal Sentiment Analysis and Emotion Recognition[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(24): 25642-25650.
<https://doi.org/10.1609/aaai.v39i24.34755>
- [15] Busso C, Bulut M, Lee C C, et al. IEMOCAP: Interactive emotional dyadic motion capture database[J]. Language resources and evaluation, 2008, 42(4): 335-359.
- [16] Poria S, Hazarika D, Majumder N, et al. MELD: A Multimodal Multi-Party Dataset for Emotion Recognition in Conversations[C]//Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. 2019: 527-536.
- [17] Hu G, Zhao Y, Lu G. Improving Representation With Hierarchical Contrastive Learning for Emotion-Cause Pair Extraction[J]. IEEE Transactions on Affective Computing, 2024, 15(4): 1997-2011.
<https://doi.org/10.1109/TAFFC.2024.3391854>
- [18] Chen Y, Hou W, Li S, et al. End-to-End Emotion-Cause Pair Extraction with Graph Convolutional Network[C]//Proceedings of the 28th International Conference on Computational Linguistics. International Committee on Computational Linguistics, 2020: 198-207.
<https://doi.org/10.18653/v1/2020.coling-main.17>
- [19] Liang Q, Shen Y, Chen T, et al. M3HG: Multimodal, Multi-scale, and Multi-type Node Heterogeneous Graph for Emotion Cause Triplet Extraction in Conversations[C]//Findings of the Association for Computational Linguistics: ACL 2025. Association for Computational Linguistics, 2025: 11416-11431.
<https://doi.org/10.18653/v1/2025.findings-acl.596>
- [20] Fu F, Ai W, Yang F, et al. SDR-GNN: Spectral Domain Reconstruction Graph Neural Network for incomplete multimodal learning in conversational emotion recognition[J]. Knowledge-Based Systems, 2025, 309: 112825.
<https://doi.org/10.1016/j.knosys.2024.112825>
- [21] Demidova A, Hamed I, Lynn T, et al. Emotion Train at SemEval-2025 Task 11: Comparing Generative and Discriminative Models in Emotion Recognition[C]//Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025). 2025.
- [22] Yang S, Li J, Zhang M, et al. FutureMind: Equipping Small Language Models with Strategic Thinking-Pattern Priors via Adaptive Knowledge Distillation[C]//International Conference on Learning Representations (ICLR 2026). 2026. <https://openreview.net/forum?id=gX42SSbjcC>
- [23] Zhong G, Huan R, Wu M, et al. Towards robust multimodal emotion recognition under missing modalities and distribution shifts[EB/OL]. 2025. arXiv:2506.10452. <https://doi.org/10.48550/arXiv.2506.10452>
- [24] Dong S. Deep at SemEval-2025 Task 11: A Multi-Stage Approach to Emotion

- Detection[C]//Proceedings of the 19th International Workshop on Semantic Evaluation (SemEval-2025). Association for Computational Linguistics, 2025: 1957-1963.
- [25] Wu D, Ju X, Zhang D, et al. Emotion across Modalities and Cultures: Multilingual Multimodal Emotion-Cause Analysis with Memory-inspired Framework[C]//Proceedings of the ACM International Conference on Multimedia (ACM MM 2025). 2025.
- [26] Ma J, Chaudhry H N, Kulsoom F, et al. MULTICAUSENET: Temporal attention for multimodal emotion cause pair extraction[J]. Scientific Reports, 2025, 15: 19372. <https://doi.org/10.1038/s41598-025-01221-w>
- [27] Ai W, Zhang F, Shou Y, et al. Revisiting multimodal emotion recognition in conversation from the perspective of graph spectrum[C]//Proceedings of the AAAI Conference on Artificial Intelligence, 2025, 39(11): 11418-11426. <https://doi.org/10.1609/aaai.v39i11.33242>
- [28] Wang B, Tang K, Zhu P. Enhancing Emotion-Cause Pair Extraction in Conversations via Center Event Detection and Reasoning[C]//Findings of the Association for Computational Linguistics: EMNLP 2024. Association for Computational Linguistics, 2024: 10773-10783. <https://doi.org/10.18653/v1/2024.findings-emnlp.632>
- [29] Li B, Fei H, Li F, et al. Multimodal Emotion-Cause Pair Extraction with Holistic Interaction and Label Constraint[J]. ACM Transactions on Multimedia Computing, Communications and Applications, 21, 2025. <https://doi.org/10.1145/3689646>
- [30] Jeong H, Bak J. PRG-MoE: Prompt-based Routing Guided Mixture-of-Experts for Emotion Cause Pair Extraction[C]//Proceedings of the 17th Conference of the European Chapter of the Association for Computational Linguistics. Association for Computational Linguistics, 2023: 3897-3908. <https://doi.org/10.18653/v1/2023.eacl-main.240>
- [31] Gu X, Zhou Z, Meng Z, et al. EmoPrompt-ECPE: Emotion Knowledge-aware Prompt-tuning for Emotion-Cause Pair Extraction[C]//Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024). ELRA and ICCL, 2024: 5678-5688.
- [32] Jia Y, Xie J, Jivaganesh S, et al. Seeing Sound, Hearing Sight: Uncovering Modality Bias and Conflict of AI Models in Sound Localization[C]//Advances in Neural Information Processing Systems (NeurIPS 2025). 2025.
- [33] Su T, Sheng J, Ma D, et al. Mitigating Modality Bias in Multi-modal Entity Alignment from a Causal Perspective[C]//Proceedings of SIGIR 2025. 2025.
- [34] Lin H, Liu H, Cao S, et al. Unveiling Modality Bias: Automated Sample-Specific Analysis for Multimodal Misinformation Benchmarks[EB/OL]. 2025.
- [35] Tian X, Zou S, Yang Z, et al. Identifying and Mitigating Position Bias of Multi-image Vision-Language Models[C]//Proceedings of CVPR 2025. 2025.
- [36] Park J, Jang K J, Alasaly B, et al. Assessing Modality Bias in Video Question Answering Benchmarks with Multimodal Large Language Models[EB/OL]. 2024.

- arXiv:2408.12763. <https://doi.org/10.48550/arXiv.2408.12763>
- [37] Shi L, Ma C, Liang W, et al. Judging the Judges: A Systematic Study of Position Bias in LLM-as-a-Judge[C]//Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics. The Asian Federation of Natural Language Processing and the Association for Computational Linguistics, 2025: 292-314. <https://aclanthology.org/2025.ijcnlp-long.18/>
- [38] Xu T, Jing H, Li Y, et al. DeFacto: Counterfactual Thinking with Images for Enforcing Evidence-Grounded and Faithful Reasoning[C]//Proceedings of ICLR 2026. 2026.
- [39] Chen F, Huang P, Ge X, et al. Multimodal Sentiment Analysis Based on Causal Reasoning[EB/OL]. 2024. arXiv:2412.07292. <https://doi.org/10.48550/arXiv.2412.07292>
- [40] Yin W, Wang Y, Duan G, et al. Knowledge-Aligned Counterfactual-Enhancement Diffusion Perception for Unsupervised Cross-Domain Visual Emotion Recognition[C]//Proceedings of CVPR 2025. 2025.
- [41] Li Z, Wang H, Liu D, et al. Multimodal Causal Reasoning Benchmark: Challenging Multimodal Large Language Models to Discern Causal Links Across Modalities[C]//Findings of the Association for Computational Linguistics: ACL 2025. Association for Computational Linguistics, 2025: 5509-5533. <https://doi.org/10.18653/v1/2025.findings-acl.288>
- [42] Wu Z, Huang H -Y, Wu Y. Beyond Spurious Signals: Debiasing Multimodal Large Language Models via Counterfactual Inference and Adaptive Expert Routing[EB/OL]. 2025. arXiv:2509.15361. <https://doi.org/10.48550/arXiv.2509.15361>
- [43] Gerych W, Zhang H, Hamidieh K, et al. BendVLM: Test-Time Debiasing of Vision-Language Embeddings[C]//Advances in Neural Information Processing Systems. 2024: 37. <https://doi.org/10.52202/079017-1998>
- [44] Jung H, Chai J, Wang X. Adaptive Logit Adjustment for Debiasing Multimodal Language Models[C]//Proceedings of ICLR 2026. 2026.
- [45] Sun T, Wang W, Jing L, et al. Counterfactual Reasoning for Out-of-distribution Multimodal Sentiment Analysis[C]//Proceedings of the 30th ACM International Conference on Multimedia. Association for Computing Machinery, 2022: 15-23. <https://doi.org/10.1145/3503161.3548211>
- [46] Xu Y, Liu C, Wei Y. Rethinking Multimodal Learning from the Perspective of Mitigating Classification Ability Disproportion[C]//Advances in NeurIPS 2025. 2025.
- [47] Han X, Xu H. Causal Intervention and Counterfactual Reasoning for Multimodal Pedestrian Trajectory Prediction[J]. Journal of Imaging, 2025, 11(11): 379. <https://doi.org/10.3390/jimaging11110379>
- [48] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

- [49]Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT). 2019.
- [50]Liu Y, Ott M, Goyal N, et al. RoBERTa: A robustly optimized BERT pretraining approach[EB/OL]. 2019. arXiv:1907.11692.
- [51]Zhong P, Wang D, Miao C. Knowledge-enriched transformer for emotion detection in textual conversations[J]. IEEE Transactions on Affective Computing, 2024, 15(1): 215-228.
- [52]Hsu W N, Bolte B, Tsai Y H H, et al. HuBERT: Self-supervised speech representation learning by masked prediction of hidden units. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 29, 3451-3460.
- [53]Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C]//Proceedings of the International Conference on Learning Representations (ICLR). 2021.
- [54]Arnab A, Dehghani M, Heigold G, et al. ViViT: A video vision transformer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV). 2021: 6836-6846.
- [55]Qwen Team. Qwen2.5-VL Technical Report[EB/OL]. 2025. arXiv:2502.13923.
- [56]Dehghani M, Mustafa B, Djolonga J, et al. Patch n' Pack: NaViT, a Vision Transformer for any Aspect Ratio and Resolution[C]//Proceedings of Advances in Neural Information Processing Systems (NeurIPS). 2024.
- [57]Su J, Ahmed M, Lu Y, et al. RoFormer: Enhanced transformer with rotary position embedding[J]. Neurocomputing, 2024, 568: 127063.
- [58]Zhang B, Ma R, Jiang Q, et al. Sentient Agent as a Judge: Evaluating Higher-Order Social Cognition in Large Language Models[EB/OL]. 2025. arXiv:2505.02847. <https://doi.org/10.48550/arXiv.2505.02847>
- [59]Zhang Y, et al. Affective Computing in the Era of Large Language Models: A Survey from the NLP Perspective[EB/OL]. 2024. arXiv:2408.04638.
- [60]Wu C, Cai Y, Liu Y, et al. Multimodal Emotion Recognition in Conversations: A Survey of Methods, Trends, Challenges and Prospects[C]//Findings of the Association for Computational Linguistics: EMNLP 2025. Association for Computational Linguistics, 2025: 6257-6274. <https://doi.org/10.18653/v1/2025.findings-emnlp.332>
- [61]Chen R, Jiang W, Qin C, et al. Theory of Mind in Large Language Models: Assessment and Enhancement[EB/OL]. 2025. arXiv:2505.00026. <https://doi.org/10.48550/arXiv.2505.00026>
- [62]Yang Q, Ye M, Du B. EmoLLM: Multimodal Emotional Understanding Meets Large Language Models[EB/OL]. 2024. arXiv:2406.16442. <https://doi.org/10.48550/arXiv.2406.16442>
- [63]Luo M, Li B, Xu S, et al. Unveiling the Cognitive Compass: Theory-of-Mind-Guided Multimodal Emotion Reasoning[C]//International Conference on Learning Representations (ICLR 2026). 2026. <https://doi.org/10.48550/arXiv.2602.00971>

- [64]Fang Y, Liang J, Huang W, et al. Catch Your Emotion: Sharpening Emotion Perception in Multimodal Large Language Models[C]//Proceedings of the International Conference on Machine Learning (ICML 2025). 2025.
- [65]Hu E J, Shen Y, Wallis P, et al. LoRA: Low-rank adaptation of large language models[C]//Proceedings of the International Conference on Learning Representations (ICLR). 2022.
- [66]Aghajanyan A, Zettlemoyer L, Gupta S. Intrinsic dimensionality explains the effectiveness of language model fine-tuning[C]//Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics (ACL). 2021: 7319-7328.
- [67]Deng G, Li B, Chen R, et al. DR-LoRA: Dynamic Rank LoRA for Mixture-of-Experts Adaptation[EB/OL]. 2026. arXiv:2601.04823. <https://doi.org/10.48550/arXiv.2601.04823>
- [68]Cao J, Lin T, He H, et al. MoA: Heterogeneous Mixture of Adapters for Parameter-Efficient Fine-Tuning of Large Language Models[EB/OL]. 2025. arXiv:2506.05928.
- [69]Sun A, Wang X, Tan Z, et al. CuMA: Aligning LLMs with Sparse Cultural Values via Demographic-Aware Mixture of Adapters[EB/OL]. 2026. arXiv:2601.04885. <https://doi.org/10.48550/arXiv.2601.04885>
- [70]Cong P, Liu W, Yu W, et al. Rank Also Matters: Hierarchical Configuration for Mixture of Adapter Experts in LLM Fine-Tuning[EB/OL]. 2025. arXiv:2502.03884. <https://doi.org/10.48550/arXiv.2502.03884>
- [71]Pearl J. Causality: Models, Reasoning, and Inference[M]. 2nd ed. Cambridge University Press, 2009.
- [72]Schölkopf B, Locatello F, Bauer S, et al. Toward causal representation learning[J]. Proceedings of the IEEE, 2021, 109(5): 612-634.
- [73]Peters J, Janzing D, Schölkopf B. Elements of Causal Inference: Foundations and Learning Algorithms[M]. MIT Press, 2017.
- [74]Pearl J, Mackenzie D. The Book of Why: The New Science of Cause and Effect[M]. Basic Books, 2018.
- [75]Wang T, Huang J, Zhang H, et al. Visual commonsense R-CNN[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2020: 10760-10770.
- [76]Niu Y, Tang K, Zhang H, et al. Counterfactual VQA: A cause-effect look at language bias[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2021: 12700-12710.
- [77]VanderWeele T J. Explanation in Causal Inference: Methods for Mediation and Interaction[M]. New York: Oxford University Press, 2015.
- [78]Vig J, Gehrmann S, Belinkov Y, et al. Investigating gender bias in language models using causal mediation analysis[C]//Advances in Neural Information Processing Systems (NeurIPS), 33. 2020: 12388-12401.
- [79]Ghosal D, Toh V, Chia Y K, et al. AlgoPuzzleVQA: Diagnosing Multimodal Reasoning Challenges of Language Models with Algorithmic Multimodal Puzzles[C]//Proceedings of the 2025 Conference of the Nations of the Americas

- Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers). Association for Computational Linguistics, 2025: 9615-9632. <https://doi.org/10.18653/v1/2025.naacl-long.486>
- [80] Yue X, Ni Y, Zhang K, et al. MMMU: A Massive Multi-discipline Multimodal Understanding and Reasoning Benchmark for Expert AGI[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 9556-9567.
- [81] Zhang Z, Zhang A, Li M, et al. Multimodal Chain-of-Thought Reasoning in Language Models[J/OL]. Transactions on Machine Learning Research, 2024[2026-03-28]. <https://openreview.net/forum?id=y1pPWFVfvR>.
- [82] Yin Z, Hang T, Cheng Y, et al. Generative Visual Chain-of-Thought for Image Editing[EB/OL]. 2026[2026-03-28]. <https://arxiv.org/abs/2603.01893>.
- [83] Sun Q, Cui Y, Zhang X, et al. Generative Multimodal Models are In-Context Learners[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 14398-14409.
- [84] Yang L, Yu Z, Zhang T, et al. SuperCorrect: Supervising and Correcting Language Models with Error-Driven Insights[EB/OL]. 2024[2026-03-28]. <https://openreview.net/forum?id=xHRfR62oUV>.
- [85] Li H, Jiang L, Yan Q, et al. ThinkRL-Edit: Thinking in Reinforcement Learning for Reasoning-Centric Image Editing[EB/OL]. 2026[2026-03-28]. <https://arxiv.org/abs/2601.03467>.
- [86] Cadene, R., Dancette, C., Cord, M., & Parikh, D. (2019). RUBi: Reducing unimodal biases for visual question answering. Advances in neural information processing systems (NeurIPS), 32, 841-852.
- [87] Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. In Proceedings of the IEEE international conference on computer vision (ICCV) (pp. 2980-2988).
- [88] Ju X, Zhang D, Li J, et al. Enhanced Generative Framework with LLMs for Multimodal Emotion-Cause Pair Extraction in Conversations [J]. IEEE Transactions on Multimedia, 2025.
- [89] Radford A, Kim J W, Hallacy C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning. PMLR, 2021.
- [90] Shen Z, Pang Y, Rao Y, et al. CoE: A Clue of Emotion Framework for Emotion Recognition in Conversations[C]//Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Vienna, Austria: Association for Computational Linguistics, 2025: 23548-23563.
- [91] Zhao Y, Huang J, Hu J, et al. SWIFT: A Scalable Lightweight Infrastructure for Fine-Tuning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2025, 39(28).
- [92] Zadeh A, Chen M, Poria S, et al. Tensor Fusion Network for Multimodal Sentiment Analysis[C]//Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Copenhagen, Denmark: Association for Computational Linguistics, 2017: 1103-1114.

- [93]Zadeh A, Liang P P, Mazumder N, et al. Memory Fusion Network for Multi-view Sequential Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2018, 32(1): 5634-5641.
- [94]Hazarika D, Zimmermann R, Poria S. MISA: Modality-Invariant and -Specific Representations for Multimodal Sentiment Analysis[C]//Proceedings of the 28th ACM International Conference on Multimedia. New York: ACM, 2020: 1122-1131.
- [95]Bagher Zadeh A A, Liang P P, Poria S, et al. Multimodal Language Analysis in the Wild: CMU-MOSEI Dataset and Interpretable Dynamic Fusion Graph[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Melbourne, Australia: Association for Computational Linguistics, 2018: 2236-2246.
- [96]Rahman W, Hasan M K, Lee S, et al. Integrating Multimodal Information in Large Pretrained Transformers[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Online: Association for Computational Linguistics, 2020: 2359-2369.
- [97]Hinton G, Deng L, Yu D, et al. Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups[J]. IEEE Signal processing magazine, 2012, 29(6): 82-97.

硕士研究生期间研究成果

(一) 已投稿论文:

Counterfactual Multimodal Debiasing for Multimodal Emotion-Cause Pair Extraction in Conversations

(二) 参与项目

- (1) 多模态情感识别关键技术研究及其在血液舆情大数据中的应用, 2022 年广东省科技创新战略专项 (“大专项+任务清单”) 项目 (STKJ202209002), 2023.1-2025.12。
- (2) 基于溯因推理的对话情感分析关键问题研究, 国家自然科学基金面上项目 (62372283), 2024.1-2027.12。
- (3) 面向对话情感分析的多情绪标签分布学习关键技术研究, 广东省自然科学基金项目, 2024A1515010239, 2024.1-2026.12。