

姓名

求职意向：人工智能 Agent / 大模型开发工程师

电话：138-0000-0000 | 邮箱：your_email@example.com | GitHub：github.com/yourname | 城市：所在城市

教育背景

XX 大学 计算机科学与技术（本科 / 硕士）

2021.09 – 2025.06

主修：数据结构、机器学习、深度学习、自然语言处理；GPA X.X/4.0（前 X%）

专业技能

- **大模型应用**：Prompt 工程、多轮对话管理、Function Calling、RAG 检索增强、SFT/LoRA 微调与评测。
- **Agent 技术**：ReAct / Reflection / Plan-and-Solve 等推理范式，多智能体协作，意图识别、状态机与动态 workflow 编排。
- **模型与推理**：OpenAI GPT-4o、Qwen 等开源模型，本地微调模型部署（Ollama / vLLM），向量检索（Milvus）。
- **工程能力**：Python、FastAPI、PyTorch、Docker、Git；熟悉 RESTful 接口设计与异步并发。

实习经历

XX 科技有限公司 大模型算法实习生

2024.06 – 2024.12

项目：基于大模型与意图识别的 Agent 交互式专利检索系统

- 设计并落地**三级 Fallback 意图识别流水线**（规则匹配 → 远程微调模型 → OpenAI 兜底），统一输出二级意图结构，使意图**命中率达到 60% 左右**。
- 构建**意图状态机**进行多轮上下文消歧，解决“补充条件被误判为反馈”等场景，多轮对话意图准确率显著提升。
- 以规则层（关键词 + 正则）优先命中高频意图，配合远程 GPU 微调模型异步调用，将平均**响应速度提升 40% 以上**（毫秒级命中替代秒级 API 调用）。
- 自研**动态工作流引擎**（节点 + 路由 + 共享状态 + 执行 Trace）替代 if-else 硬编码，新增处理步骤仅需 3 行代码，显著降低维护成本。
- 基于 FastAPI 实现聊天 Web 服务与实时状态面板，对接 Milvus 完成专利检索与结构化回复生成。

项目经历

HelloAgents 轻量级多智能体框架 核心开发

2025.01 – 2025.04

技术栈：Python · OpenAI 兼容 API · RAG · 强化学习 · MCP 协议

- 基于“一切皆为工具”的设计理念，从零实现 ReAct / Reflection / Plan-and-Solve 等多种 Agent 范式与统一的 LLM / Message / Config 抽象。
- 将 Memory、RAG、RL、MCP 协议统一抽象为 Tools，简化调用链路；引入检索缓存与并发优化，端到端**推理速度提升 40% 以上**。
- 搭建智能体评测模块，针对工具调用与问答任务持续迭代，使任务**命中率达到 60% 左右**，并完善单元测试与示例文档。
- 支持 ModelScope / Ollama 等多 provider 自动检测与流式输出，提供从基础对话到复杂推理的完整范式实现。

其他

- 持续跟进大模型与 Agent 前沿（LangGraph、MCP、RAG 优化等），具备较强的工程落地与快速学习能力。
- 英语 CET-6，可流畅阅读英文技术文档与论文。