

姓名

求职意向：人工智能 Agent / 大模型开发工程师

电话：138-0000-0000 | 邮箱：your_email@example.com | GitHub：github.com/yourname | 城市：所在城市

教育背景

XX 大学 计算机科学与技术（本科 / 硕士）

2021.09 – 2025.06

主修：数据结构、机器学习、深度学习、自然语言处理；GPA X.X/4.0（前 X%）

专业技能

- 大模型与微调**：Transformer / 注意力机制原理；GPT-4o、Claude、Qwen2.5、DeepSeek、Llama3 等模型应用；SFT、LoRA / QLoRA 参数高效微调、DPO / RLHF 偏好对齐、量化（GPTQ / AWQ）与蒸馏；基于 LLaMA-Factory / PEFT 的训练流水线。
- Agent 与编排**：ReAct、Reflexion、Plan-and-Solve、Tree-of-Thoughts 等推理范式；Function Calling / Tool Use、ReWOO、Multi-Agent 协作（Planner-Worker-Solver）；LangGraph、LangChain、AutoGen、CrewAI 及自研有向图工作流引擎；MCP（Model Context Protocol）工具接入。
- RAG 与检索**：Naive / Advanced / Agentic RAG、GraphRAG；文档分块（语义切分）、bge-m3 / BGE-reranker 向量化与重排、HyDE、Query Rewrite、混合检索（BM25 + 向量）；Milvus、Qdrant、FAISS、Elasticsearch 向量库。
- 推理与部署**：vLLM、Ollama、TGI 高吞吐推理；PagedAttention、KV-Cache、连续批处理、流式输出（SSE）；Prompt 缓存与并发限流。
- 工程栈**：Python、FastAPI、PyTorch、asyncio、Redis、PostgreSQL、Docker、Git / CI；RESTful / WebSocket 接口设计、可观测性（Trace / 日志）与单元测试。

实习经历

XX 科技有限公司 大模型算法实习生（AI Agent 方向）

2024.06 – 2024.12

项目：基于大模型与意图识别的 Agent 交互式专利检索系统（FastAPI · Milvus · 微调模型 · LangGraph 思想）

- 主导设计**三级 Fallback 意图识别流水线**——「规则匹配（关键词 + 正则）→ 领域微调模型（基于 Qwen 做 SFT/LoRA 的二级意图图分类器）→ GPT-4o 兜底」，统一约束输出 {level1: [level2]} 结构化 Schema 并做格式校验与自动重试，使意图命中率提高 **60% 左右**。
- 设计**意图状态机（IntentStateMachine）**实现多轮上下文消歧，以「（当前状态, 原始意图）→（新状态, 修正动作）」转移表解决「补充检索条件被误判为反馈/修改」等歧义场景，多轮对话意图准确率显著提升、追问轮次明显下降。
- 通过规则层毫秒级命中高频意图、远程 GPU 微调模型**异步并发**调用、并对意图与 Embedding 结果做缓存，将**平均响应速度提升 40% 以上**（以本地命中替代秒级 LLM API 往返），同时降低 Token 成本。
- 自研**动态工作流引擎**（Node + Router + 共享 State + 执行 Trace 的有向图编排），以 11 个节点 / 5 条路由替代 if-else 硬编码，新增处理步骤仅需约 3 行代码，显著提升可维护性与可观测性。
- 构建**实体抽取与槽位记忆**模块（专利号正则 + 技术领域词典 + LLM 补全缺失槽位）与完整性评估节点，自动追问引导用户补全检索条件后再确认执行。
- 基于 FastAPI 实现聊天 Web 服务、实时状态面板与 SSE 流式回复，对接 Milvus 向量检索完成专利召回、重排与结构化报告生成。

项目经历

HelloAgents 轻量级多智能体框架 核心开发

2025.01 – 2025.04

技术栈：Python · OpenAI 兼容 API · RAG · 强化学习 · MCP 协议 · ModelScope / Ollama

- 基于「一切皆为工具（Everything-as-Tools）」的设计理念从零构建多智能体框架，抽象统一的 LLM / Message / Config 内核，并实现 ReAct、Reflection、Plan-and-Solve 等多种 Agent 推理范式。
- 将 Memory（短期/长期记忆）、RAG、强化学习（RL）、MCP 协议统一抽象为可插拔 Tools，消除冗余抽象层；引入检索缓存、上下文工程（Context Engineering）与并发调度，端到端**推理速度提升 40% 以上**。
- 搭建 Agent 评测（Evaluation）模块，对工具调用准确率与问答任务做指标化迭代（含 ReAct 轨迹分析），使任务**命中率提高 60% 左右**，并完善单元测试、conftest 与示例脚本。
- 实现多 Provider 自动检测（OpenAI / ModelScope / Ollama）与**流式输出（stream_run）**，支持本地与云端模型无缝切换；编写第七章「构建你的智能体框架」配套教程与 API 文档。

其他项目与能力

- 企业知识库问答（RAG）**：基于 bge-m3 向量化 + BGE-reranker 重排 + Milvus 的混合检索问答，结合 HyDE 与 Query Rewrite 优化召回，缓解大模型幻觉。
- 持续跟进大模型与 Agent 前沿（LangGraph、MCP、Agentic RAG、GraphRAG、DPO 对齐等），具备扎实的工程落地与快速学习能力。
- 英语 CET-6，可流畅阅读英文技术文档与前沿论文（arXiv）。